



Predicción de presencia de CO en el aire de Santiago

Autor: Jaime Alonso C.

Curso: Análisis de Regresión EYP230I

INTRODUCCIÓN

La contaminación atmosférica es uno de los principales problemas ambientales en el área metropolitana de Santiago de Chile, donde las concentraciones de **monóxido de carbono (CO)** están fuertemente influenciadas por el tráfico vehicular y las condiciones meteorológicas. Este contaminante, producto de procesos de combustión incompleta, presenta una marcada variabilidad temporal y estacional, lo que dificulta su modelación y predicción.

En este trabajo se propone un modelo de regresión lineal múltiple para la predicción diaria de la concentración de CO en Santiago, utilizando datos oficiales del sistema **SINCA**, obtenidos de la estación **Parque O'Higgins**.

Estación Parque O'Higgins



Información general	
Propietario	Ministerio del Medio Ambiente
Operador	Ministerio del Medio Ambiente
Región	Metropolitana de Santiago
Provincia	Santiago
Comuna	Santiago
Coordenadas UTM	345673 E 6296019 N
Huso horario	19
Recepción de datos	en línea
Inicio de operación reportada	1997-03-08

ANÁLISIS DE LAS VARIABLES

El centro entrega los siguientes datos: el contaminante (elegido) y las variables metereológicas disponibles. Para el contaminante se entregan 3 tipos de datos, **validados**, **preeliminares** y **no validados**.

Dato	Unidad de medida	Frecuencia	Rango de registros	Número de datos válidos	% de nulos
Monóxido de carbono	ppm	Diaria	08/04/1997 - 13/12/2025	9.942	5.1%*
Temperatura Ambiente	°C	Horaria	15/12/2003 - 13/12/2025	188.554	2.2%
Humedad Relativa	%	Horaria	15/12/2003 - 13/12/2025	187.430	2.8%
Velocidad del Viento	m/s	Horaria	15/12/2003 - 13/12/2025	184.902	4.1%

*Este valor incluye la incorporación de datos preeliminares y no validados al estudio.

Para la realización de este estudio, se realizará la división de los datos del contaminante de la siguiente manera: **(72%) Entrenamiento**, **(18%) Validación** y **(10%) Prueba del modelo**.

ELECCIÓN DE MODELO

Para la realización de este modelo, partimos utilizando el criterio stepwise foward de acuerdo **BIC**, sobre los datos metereológicos. Obteniendo el modelo completo de:

$$CO_t = \beta_0 + \beta_1 Temperatura_t + \beta_2 Humedad_t + \beta_3 Velocidad\ del\ viento_t + \epsilon_t$$

*Donde CO_t es la concentración diaria de monóxido de carbono y ε_t representa el error aleatorio.

Dado que el modelo presentaba un R² del 0.4 y un error cuadrático medio del 0.403 (con los datos de validación), se propuso implementar la variable mes aceptada por el criterio BIC. Ante esto fue posible detectar colinealidad entre mes y temperatura

Variable	VIF ajustado	Interpretación
Mes	1,22	Aceptable (< 5)
Temperatura	7,69	Colinealidad alta (> 5)
Viento	2,27	Aceptable (< 5)
Humedad	2,55	Aceptable (< 5)

Matriz de Correlación: Variables Meteorológicas


CO	1	-0.49	-0.55	0.27
Temperatura	-0.49	1	0.49	-0.75
Viento	-0.55	0.49	1	-0.26
Humedad	0.27	-0.75	-0.26	1
	CO	Temperatura	Viento	Humedad

ANÁLISIS DE RESIDUOS

Los residuos presentan desviaciones de la normalidad en las colas, fenómeno habitual en series ambientales diarias. Dado que no se detectó autocorrelación residual (DW ≈ 2) y se utilizaron errores estándar robustos (HC3), no fue necesaria una transformación de la variable respuesta.

Dado el alto grado de colinealidad entre temperatura y mes (VIF > 5), se optó por representar la estacionalidad mediante variables indicadoras mensuales, excluyendo temperatura del modelo final. Esta decisión mejora la estabilidad del modelo sin pérdida sustantiva de capacidad predictiva. Por lo que el modelo cambiaría a:

$$CO_t = \beta_0 + \sum_{m=2}^{12} \beta_m \cdot Mes_m + \beta_1 \cdot Viento_t + \beta_2 \cdot Humedad_t + \epsilon_t$$




MODELO FINAL

El modelo de regresión lineal múltiple explicó un **51% de la variabilidad diaria del CO** en la estación de Santiago, lo que representa un ajuste moderado-alto para una serie ambiental altamente volátil. El estadístico de Durbin-Watson (DW = 1.95) indica **ausencia de autocorrelación residual relevante**, validando la estructura temporal del modelo. El test de Breusch-Pagan (p < 0.001) evidenció **heterocedasticidad**, por lo que la inferencia se realizó utilizando errores estándar robustos (HC3).

Variable	Estimación	Error Std.	t	p
Intercepto	944	42	2.259	<0.001***
Mes 2	34	19	176	0.078•
Mes 3	59	22	274	0.006**
Mes 4	254	29	887	<0.001***
Mes 5	680	44	1.549	<0.001***
Mes 6	1.043	57	1.816	<0.001***
Mes 7	1.014	54	1.865	<0.001***
Mes 8	601	44	1.371	<0.001***
Mes 9	225	30	744	<0.001***
Mes 10	21	23	91	361
Mes 11	-0.009	20	-0.48	631
Mes 12	26	20	129	198
Viento	-0.206	25	-8.24	<0.001***
Humedad	-0.006	1	-8.30	<0.001***

*Salida del código en R, con los coeficientes ajustados por (HC3), explicando los coeficientes.

PREDICCIÓN



La predicción entregada fue la siguiente, para los datos históricos del contaminante: (datos de entrenamiento)

Estadístico	Valor (ppm)
Media	0,71
Mediana	0,54
Desviación estándar	0,56
Mínimo	0,00
Máximo	5,20
Percentil 25 (Q1)	0,31
Percentil 75 (Q3)	0,94

Donde, para dicho período, los datos entregados por SINCA del contaminante son los siguientes, por lo que se obtuvo resultados muy similares a la realidad.

