



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA

Modelos Predictivos de Asfixia Intraparto

**Jaime Alonso
Clemente Bordeu
René Prieto**

Trabajo de Título para optar al título de Ingeniero Civil Matemático y Computacional, e Ingeniero Civil de Industrias con Diploma en Ingeniería Matemática.

Profesores Guía:
Alejandro Cataldo, Daniel Zúñiga

Santiago de Chile, junio, 2026



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA MATEMÁTICA Y
COMPUTACIONAL

Modelos Predictivos de Asfixia Intraparto

**Jaime Alonso
Clemente Bordeu
René Prieto**

Trabajo de Título presentado a la Comisión integrada
por los profesores:

Alejandro Cataldo

Daniel Zúñiga

Para completar las exigencias del título de Ingeniero
Civil Matemático y Computacional, e Ingeniero Civil
de Industrias con Diploma en Ingeniería Matemática.

Santiago de Chile, junio, 2026

(A nuestros Padres, hermanos y amigos,
que nos apoyaron mucho.)

AGRADECIMIENTOS

Agradecemos la colaboración del doctor Pablo Moore Ross, del Hospital de Puerto Montt y de Mircea Petrache, del Instituto de Ingeniería Matemática y Computacional, por hacer posible este proyecto. Agradecemos también la supervisión y colaboración de los profesores Alejandro Cataldo y Daniel Zúñiga del Instituto de Ingeniería Matemática y Computacional.

INDICE GENERAL

DEDICATORIA

AGRADECIMIENTOS

INDICE GENERAL

INDICE DE FIGURAS

RESUMEN

ABSTRACT

1	INTRODUCCIÓN	1
1.1	Contexto y Problema	1
1.2	Objetivos del Proyecto	2
1.3	Entregables del Proyecto	3
2	EXPLORACIÓN Y MANEJO DE DATOS	5
2.1	Descripción de los Datos	5
2.2	Análisis de Outcomes Clínicos	6
2.2.1	Distribución de outcomes y definición del label	6
2.2.2	Definición del outcome compuesto (Estrategia B)	8
2.3	Análisis Exploratorio de la Señal CTG	8
3	AMPLIACIÓN DE LA MUESTRA	11
3.1	Motivación y elección del modelo de bootstrap	11
3.2	Bootstrap multivariado sincronizado	12
3.3	Filtrado de registros elegibles	13
3.4	Selección del tamaño de bloque b^*	13
3.5	Determinación del número de réplicas	14
3.6	Validación de fidelidad	14
4	EXTRACCIÓN DE CARACTERÍSTICAS	17
4.1	Pipeline de extracción	17
4.2	Características extraídas	17
4.3	Características longitudinales para el modelo secuencial	18
5	MODELAMIENTO Y RESULTADOS	20
5.1	Diseño del experimento y control de fugas de información	20
5.2	Anclaje temporal del label	21

5.3	Fase 1: Evaluación univariada sobre ventanas	22
5.4	Fase 2: Selección multivariada Forward sobre ventanas	23
5.4.1	Modelo AIC: 23 variables con tendencias temporales	23
5.4.2	Modelo BIC: 5 variables parsimoniosas	23
5.4.3	Comparación de desempeño en la Fase 2	24
5.5	Fase 3: Modelos secuenciales avanzados (XGBoost y CatBoost)	25
5.5.1	Hiperparámetros optimizados	25
5.5.2	Importancia de características	26
5.5.3	Evaluación clínica de alerta temprana	27
5.5.4	Análisis estratificado por endpoint	29
5.6	Comparación global entre fases	29
6	DISCUSIÓN	31
6.1	Interpretación de los resultados	31
6.2	Limitaciones	32
6.3	Coherencia con la fisiopatología	32
7	PLAN DE CONTINUIDAD	34
7.1	Integración de los datos del Hospital de Puerto Montt	34
7.2	Mejoras técnicas identificadas	34
8	CONCLUSIONES	36
9	REFERENCIAS BIBLIOGRÁFICAS	38

INDICE DE FIGURAS

2-1	Análisis de outcomes de asfixia intraparto en los 552 registros originales del CTU-UHB. Panel superior izquierdo: categorías clínicas combinadas. Panel superior central y derecho: dispersión pH vs. Apgar5 y pH vs. Apgar1, respectivamente, con umbrales diagnósticos superpuestos. Panel inferior: distribución de pH umbilical, distribución comparada de Apgar1 y Apgar5, y conteo por criterio diagnóstico.	7
2-2	Análisis de la puntuación Apgar en los 552 registros originales del CTU-UHB. Panel izquierdo: distribución comparada de Apgar al minuto 1 y al minuto 5. Panel central: conteo de casos por criterio basado en Apgar. Panel derecho: dispersión Apgar1 vs. Apgar5, con casos con algún Apgar < 7 resaltados en rojo.	8
2-3	Análisis exploratorio del dataset CTU-UHB (originales y sintéticos). Fila superior: distribuciones de pH umbilical, Apgar1 y Apgar5 en registros originales (azul) y sintéticos (rojo). Fila central: dispersión pH vs. Apgar1 y Apgar5, FHR media por grupo Apgar1. Fila inferior: criterios de asfixia ACOG, factores de riesgo maternos y distribución de tipo de parto.	9
2-4	Serie de tiempo del registro 1001 del dataset CTU-UHB. Panel superior: frecuencia cardíaca fetal (FHR) en lpm. Panel inferior: actividad uterina (UC) en mmHg. Señales muestreadas a 4 Hz. Adaptado de Chudácek et al. (2014).	10
3-1	Trazados CTG originales (azul) versus sintéticos (rojo) para cuatro registros representativos generados con Stationary Bootstrap. Las series sintéticas reproducen la morfología, amplitud y dinámica temporal de las señales originales sin introducir discontinuidades artificiales.	13
3-2	Diagnóstico de autocorrelación (ACF) del Stationary Bootstrap. <i>Izquierda</i> : curva ACF media ± 1 desviación estándar para registros originales (azul) y sintéticos (rojo). <i>Centro</i> : sesgo punto a punto $ACF_{orig} - ACF_{synt}$ por desfase. <i>Derecha</i> : distribución del tiempo de memoria por registro.	14
3-3	Validación de fidelidad del Stationary Bootstrap. De izquierda a derecha y de arriba a abajo: histogramas de distribución marginal FHR y UC, función de autocorrelación media FHR, densidad espectral de potencia FHR (escala logarítmica), función de correlación cruzada $FHR \leftrightarrow UC$, y tabla resumen de métricas con umbrales de referencia.	15

3-4	Reporte de fidelidad del Stationary Bootstrap. Comparación distribucional detallada entre registros originales y sintéticos en las dimensiones de distribución marginal, autocorrelación y densidad espectral de potencia, confirmando la preservación de todas las propiedades estadísticas clave de la señal CTG.	16
5-1	Importancia de características (ganancia media) para el modelo XGBoost secuencial real-only (Fase 3). Las 25 características más importantes muestran un balance entre variables demográficas (Age, Weight_g, Gest_weeks), morfológicas (accelerations_count, fhr_baseline_std_bpm, fhr_baseline_median_bpm) y de complejidad no lineal (slope_sampen_30min, dfa_alpha). La característica longitudinal slope_sampen_30min figura entre las 10 más importantes.	27

RESUMEN

La asfixia intraparto afecta entre 2 y 10 de cada 1.000 nacidos vivos y es la tercera causa de mortalidad neonatal en los países de ingresos altos, tras la prematuridad y las malformaciones congénitas. Pese a seis décadas de uso extendido, la monitorización electrónica fetal presenta concordancia interobservador baja y un valor predictivo positivo inferior al 50 %, lo que motiva el desarrollo de herramientas algorítmicas de apoyo. Este trabajo construye y valida un marco predictivo basado en Machine Learning para la detección anticipada de asfixia intraparto, desarrollado en colaboración con el Hospital de Puerto Montt sobre el dataset público CTU-UHB (552 registros intraparto), capturado con el mismo sistema de monitorización Philips (ObTraceVue) que opera el hospital.

La metodología se estructuró en cuatro etapas: (1) análisis de outcomes clínicos y definición de la variable de respuesta como outcome compuesto ($\text{pH} < 7,10$ ó $\text{Apgar5} < 7$, prevalencia 12,1 %; el ingreso a UCI se descartó por ser cero en toda la cohorte); (2) aumento de la muestra mediante *Stationary Bootstrap* multivariado sincronizado sobre 487 registros elegibles, con fidelidad estadística validada; (3) extracción de 41 características (35 de ventana más 6 de tendencia longitudinal) sobre ventanas deslizantes de 20 minutos con paso de 5 minutos, con exclusión explícita de variables post-outcome para evitar fugas de información; (4) entrenamiento y comparación de modelos (regresión logística, XGBoost y CatBoost) bajo validación cruzada anidada a nivel de paciente, con anclaje temporal de la etiqueta e intervalos de confianza por *bootstrap*.

El modelo de mejor desempeño fue el **XGBoost**, con un AUROC de 0,626 (IC95 0,550–0,701) a nivel de paciente. Supera a CatBoost de forma estadísticamente distinguible, pero queda empatado con la regresión logística (AUROC 0,605), de modo que con 57 pacientes positivos el ordenamiento entre las mejores arquitecturas debe leerse como evidencia exploratoria y no como una jerarquía definitiva. Dos resultados son centrales. Primero, bajo la metodología corregida el poder predictivo descansa en la señal cardiotocográfica y no en la demografía materna basal (que queda cerca del azar en la ablación), gracias al control de fugas y a la validación estratificada por paciente; el anclaje temporal de la etiqueta aporta la definición clínicamente interpretable de la tarea de alerta temprana. Segundo, al restringir la definición al endpoint de asfixia severa real ($\text{pH} < 7,00$ y déficit de base ≥ 12 mEq/L, 9 casos), el desempeño cae al azar (AUROC 0,412), lo que evidencia que el buen desempeño sobre el outcome compuesto proviene de sus criterios más laxos (acidosis moderada y depresión neonatal) y no equivale a detectar la asfixia severa. El entregable de valor es el marco metodológico reproducible y libre de fugas, cuya validación clínica requiere la cohorte de mayor tamaño del Hospital de Puerto Montt.

Palabras clave: asfixia intraparto, cardiotocografía, Machine Learning, XGBoost, Stationary Bootstrap, validación por paciente, alerta temprana, ventanas deslizantes.

ABSTRACT

Intrapartum asphyxia affects between 2 and 10 out of every 1,000 live births and is the third leading cause of neonatal death in high-income countries, after prematurity and congenital malformations. Despite six decades of widespread use, electronic fetal monitoring shows low interobserver agreement and a positive predictive value below 50%, motivating the development of algorithmic decision-support tools. This work builds and validates a Machine Learning predictive framework for the early detection of intrapartum asphyxia, developed in collaboration with the Hospital de Puerto Montt using the public CTU-UHB dataset (552 intrapartum records), captured with the same Philips monitoring system (ObTraceVue) operated by the hospital.

The methodology comprised four stages: (1) clinical outcome analysis and definition of a composite response variable ($\text{pH} < 7.10$ or $\text{Apgar}5 < 7$; prevalence 12.1%; NICU stay was dropped as it is zero across the cohort); (2) sample augmentation via multivariate synchronised Stationary Bootstrap over 487 eligible records, with validated statistical fidelity; (3) extraction of 41 features (35 window features plus 6 longitudinal trend features) on 20-minute sliding windows with a 5-minute stride, with explicit exclusion of post-outcome variables to prevent data leakage; (4) training and comparison of models (logistic regression, XGBoost and CatBoost) under patient-level nested cross-validation, with temporal label anchoring and bootstrap confidence intervals.

The best-performing model was **XGBoost**, with a patient-level AUROC of 0.626 (95% CI 0.550–0.701). It outperforms CatBoost by a statistically distinguishable margin but is tied with logistic regression (AUROC 0.605), so with 57 positive patients the ordering among the leading architectures should be read as exploratory evidence rather than a definitive ranking. Two findings are central. First, under the corrected methodology the predictive power rests on the cardiotocographic signal rather than on baseline maternal demographics (which sit near chance in the ablation), owing to leakage control and patient-level cross-validation; temporal label anchoring provides the clinically interpretable definition of the early-warning task. Second, when the definition is restricted to true severe acidaemia ($\text{pH} < 7.00$ and base deficit ≥ 12 mEq/L, 9 cases), performance drops to chance (AUROC 0.412), showing that the composite outcome's apparent performance stems from its more lenient criteria (moderate acidosis and low Apgar) and does not equate to detecting severe acidaemia. The deliverable of value is the reproducible, leakage-free methodological framework, whose clinical validation requires the larger cohort of the Hospital de Puerto Montt.

Keywords: intrapartum asphyxia, cardiotocography, Machine Learning, XGBoost, Stationary Bootstrap, patient-level validation, early warning, sliding windows.

1. INTRODUCCIÓN

1.1. Contexto y Problema

El Hospital de Puerto Montt “Dr. Eduardo Schütz Schroeder” es el principal establecimiento de salud de la Región de Los Lagos y la cabecera asistencial del Servicio de Salud Reloncaví. Como hospital de alta complejidad, concentra la atención obstétrica de referencia de la macrozona sur, incluyendo los embarazos de alto riesgo. Su Unidad de Alto Riesgo Obstétrico (ARO) es la encargada del manejo clínico de pacientes con condiciones que comprometen el bienestar materno-fetal. Como parte de su equipamiento, el hospital opera una central de monitoreo Philips ObTraceVue que ha almacenado de forma estructurada los registros electrónicos de monitorización fetal de todas las pacientes en trabajo de parto desde el año 2014. Esta base de datos digital, de aproximadamente 20.000 registros, es un activo único en el país por su volumen y horizonte temporal, posicionando al hospital como una plataforma excepcional para el desarrollo de herramientas predictivas en obstetricia.

El presente trabajo se enmarca en una colaboración entre el hospital y el Instituto de Ingeniería Matemática y Computacional (IMC) de la Pontificia Universidad Católica de Chile, articulada a través del Dr. Pablo Moore Ross, obstetra del recinto, y del profesor Mircea Petrache, académico del IMC. La motivación central es aprovechar esta extensa base histórica para construir modelos matemáticos que apoyen la detección anticipada de eventos de asfixia intraparto, uno de los problemas más persistentes en la práctica clínica actual.

El parto constituye uno de los eventos fisiológicamente más exigentes en la vida humana. Cada contracción uterina interrumpe transitoriamente el flujo sanguíneo uteroplacentario, reduciendo el aporte de oxígeno al feto. En condiciones normales, el feto dispone de mecanismos compensatorios para tolerar estos episodios, tales como la redistribución del gasto cardíaco hacia órganos vitales, bradicardia refleja y liberación de catecolaminas. Sin embargo, cuando las contracciones son demasiado frecuentes o intensas, o la reserva placentaria está comprometida, estos mecanismos resultan insuficientes. Se desencadena entonces una cascada de deterioro: hipoxemia, hipercapnia, metabolismo anaeróbico y, finalmente, acidosis metabólica con potencial daño cerebral irreversible.

Este cuadro clínico se conoce como asfixia intraparto. En la práctica moderna se utilizan marcadores bioquímicos objetivos para su diagnóstico, destacando un pH en arteria umbilical inferior a 7,00 y un déficit de base menor o igual a -12 mEq/L (Ayres-de-Campos et al., 2015). Su consecuencia más grave es la Encefalopatía Hipóxico-Isquémica (EHI), evaluada clínicamente mediante la escala de Sarnat (Sarnat & Sarnat, 1976), la cual ocurre en aproximadamente 1 a 6 de cada 1.000 nacidos vivos a término. En los países de ingresos altos la asfixia perinatal constituye la tercera causa de mortalidad neonatal, tras la prematuridad y las malformaciones congénitas, afectando

entre 2 y 10 de cada 1.000 nacidos vivos (Lawn et al., 2005).

A pesar de que la Monitorización Electrónica Fetal (MEF) lleva más de seis décadas de uso extendido para prevenir estos eventos, la evidencia muestra que su interpretación visual presenta limitaciones críticas (Alfirevic et al., 2017):

- **Alta variabilidad interobservador:** La concordancia entre clínicos al clasificar un mismo trazado es sustancialmente baja, incluso entre especialistas experimentados, con índices Kappa que frecuentemente se sitúan por debajo de 0,5 (Alfirevic et al., 2017).
- **Bajo valor predictivo positivo:** En la mayoría de los estudios, el valor predictivo positivo de la MEF para acidosis metabólica significativa es inferior al 50 %, lo que se traduce en una alta tasa de intervenciones innecesarias (Alfirevic et al., 2017).
- **Falsos negativos clínicamente relevantes:** Trazados clasificados como de categoría I pueden fallar en detectar fetos en riesgo, particularmente en patrones de hipoxia gradualmente progresiva (Tarvonen et al., 2021).
- **Subjetividad y fatiga:** Los sistemas vigentes se basan en la apreciación visual de parámetros aislados, haciendo al observador vulnerable a la fatiga y a la dificultad humana de integrar múltiples señales simultáneas en tiempo real.

Paradójicamente, la implementación masiva de la MEF se ha asociado a un aumento sostenido de la tasa de cesáreas sin una reducción proporcional en los resultados adversos neurológicos (Alfirevic et al., 2017). Esto refleja que el problema no radica en la señal capturada, sino en el proceso de interpretación. Existe un espacio claro para que las herramientas de Machine Learning contribuyan a reducir la subjetividad y extraer patrones temporales sutiles que escapan al análisis visual.

1.2. Objetivos del Proyecto

El objetivo general de este trabajo es desarrollar y validar un marco algorítmico predictivo, basado en técnicas de Machine Learning, capaz de identificar de forma anticipada eventos de asfixia intraparto a partir de series de tiempo de monitorización electrónica fetal. Se priorizó una sensibilidad clínicamente aceptable, en concordancia con los altos costos asimétricos asociados a los falsos negativos en contextos obstétricos críticos.

Para lograr este objetivo, se contemplaron las siguientes tareas, todas las cuales fueron ejecutadas sobre el dataset público CTU-UHB ante la no disponibilidad de los datos hospitalarios durante el período de desarrollo:

1. Caracterizar los outcomes clínicos del dataset CTU-UHB y definir la variable de respuesta

mediante criterios bioquímicos y clínicos objetivos.

2. Implementar un mecanismo de generación de datos sintéticos representativo de la fisiología fetal mediante *Stationary Bootstrap* multivariado.
3. Realizar un análisis exploratorio sobre las señales de frecuencia cardíaca fetal y dinámica uterina, extrayendo un conjunto de características clínicamente informadas en ventanas deslizantes de 20 minutos.
4. Construir, ajustar y comparar modelos predictivos en tres fases: evaluación univariada sobre ventanas, evaluación multivariada mediante selección *Forward* con criterios AIC (Akaike, 1974) y BIC (Schwarz, 1978), y modelos de árboles de decisión potenciados (XGBoost (Chen & Guestrin, 2016) y CatBoost) con características longitudinales.
5. Validar el desempeño de los modelos priorizando métricas clínicamente significativas: sensibilidad, AUROC, *Patient Recall* y tiempo de alerta anticipada.
6. Implementar un sistema de evaluación secuencial que simule el monitoreo en tiempo real, estimando el tiempo de alerta anticipada a nivel de paciente.

El alcance del presente trabajo se circunscribe al desarrollo, ajuste y validación retrospectiva de los modelos predictivos sobre registros históricos del dataset público CTU-UHB. No contempla la implementación en línea sobre flujos de datos en tiempo real ni la integración directa con los sistemas informáticos del hospital. Como línea de continuidad futura, se propone extender este trabajo hacia el desarrollo de un sistema piloto en tiempo real que opere como un “copiloto” para el equipo clínico, generando alertas tempranas calibradas para apoyar la toma de decisiones sin reemplazar el juicio médico, una vez disponibles los datos del Hospital de Puerto Montt.

1.3. Entregables del Proyecto

Los siguientes entregables fueron desarrollados en estricto cumplimiento de la normativa nacional vigente, además de los principios de la Declaración de Helsinki (Biblioteca del Congreso Nacional de Chile, 1999; 2006; 2012; World Medical Association, 2013):

- **Pipeline de preprocesamiento y extracción de características** reproducible, que procesa registros CTG desde los archivos de señal crudos hasta un dataset tabular de 41 características en total (35 estáticas de ventana más 6 de tendencia longitudinal), listo para modelamiento.
- **Dataset sintético validado** de 974 series generadas mediante *Stationary Bootstrap* multivariado, con métricas de fidelidad estadística documentadas.
- **Conjunto de modelos predictivos validados**, abarcando enfoques lineales (regresión logística Forward AIC/BIC) y no lineales (XGBoost y CatBoost secuencial), con métricas de

desempeño documentadas y clínicamente interpretables.

- **Informe técnico** detallando la metodología empleada, los resultados experimentales y un análisis sobre la factibilidad del uso clínico.
- **Código fuente reproducible**, implementado en Python (numpy, pandas, scipy, scikit-learn, statsmodels, XGBoost, CatBoost), organizado en un pipeline modular que permite replicar el preprocesamiento, la extracción de características, el entrenamiento y la evaluación por validación cruzada anidada. El código está disponible en el repositorio del proyecto.¹

¹<https://github.com/jialonsoc/IMT3140>

2. EXPLORACIÓN Y MANEJO DE DATOS

2.1. Descripción de los Datos

La fuente de datos primaria contemplada por este proyecto corresponde a los registros electrónicos almacenados en la central de monitoreo Philips ObTraceVue del Hospital de Puerto Montt. Sin embargo, al cierre del período de desarrollo, esta base no se encontraba disponible para análisis por parte del equipo, debido a procesos administrativos de autorización y dificultades técnicas en la extracción desde los equipos. Se activó entonces el plan de contingencia, consistente en trabajar con la base pública **CTU-UHB Intrapartum Cardiotocography Database** (Chudáček et al., 2014), recopilada en el Hospital Universitario de Brno (República Checa).

El dataset CTU-UHB contiene 552 registros intraparto, anotados clínicamente y curados, donde cada caso aporta dos series de tiempo principales muestreadas a una frecuencia de 4 Hz, la frecuencia cardíaca fetal (FHR) expresada en latidos por minuto, y la actividad uterina (UC) expresada en milímetros de mercurio. Cada registro está acompañado por un encabezado con metadatos clínicos clasificables en cinco grupos funcionales, resumidos en la Tabla 2-1.

Tabla 2-1: Estructura de variables del dataset CTU-UHB. Adaptado de Chudáček et al. (2014).

Grupo	Variables principales
Identificación del registro	Record ID, dbID, tipo de sensor (1: Doppler externo; 2: electrodo interno), posición de inicio de segunda etapa, tiempo entre fin de señal y nacimiento.
Señal CTG	FHR (bpm, 4 Hz) y UC (mmHg, 4 Hz).
Factores maternos	Edad materna, gravidez, paridad, diabetes, hipertensión, preeclampsia, rotura prematura de membranas, pirexia, presencia de meconio.
Descriptores del parto	Presentación fetal, inducción del parto, duración de la primera y segunda etapa, diagnóstico de falta de progreso, tipo de parto.
Outcomes neonatales	pH arteria umbilical, exceso de base (BE), BDecf, pCO ₂ , Apgar al minuto 1 y 5, días en UCI neonatal, convulsiones, EHI, intubación.

La adecuación del dataset CTU-UHB para este proyecto se fundamenta en tres aspectos. Primero, las señales de FHR y UC son exactamente las mismas variables capturadas por la central Philips del Hospital de Puerto Montt, garantizando compatibilidad estructural del pipeline desarrollado. Segundo, la frecuencia de muestreo de 4 Hz es estándar en cardiotocografía moderna y

permite calcular tanto la variabilidad a largo plazo como métricas de complejidad no lineal. Tercero, el dataset cuenta con anotaciones objetivas del outcome neonatal que permiten construir el label binario del problema de la misma forma en que se construirá sobre los datos hospitalarios.

2.2. Análisis de Outcomes Clínicos

2.2.1. Distribución de outcomes y definición del label

Como paso previo al modelamiento, se realizó un análisis exhaustivo de los outcomes neonatales disponibles en el dataset para fundamentar la elección de la variable de respuesta. Este análisis se aplicó únicamente sobre los 552 registros originales (sin sintéticos), con el fin de caracterizar la distribución clínica real de la cohorte.

El análisis implementó seis criterios diagnósticos de asfixia intraparto de complejidad creciente, cuyos resultados se resumen en la Tabla 2-2. La cohorte presenta una distribución favorable para el desarrollo de modelos predictivos, dado que la mayoría de los nacimientos tienen outcomes normales, aunque existe una proporción suficientemente alta de casos de riesgo para permitir el entrenamiento de clasificadores.

Tabla 2-2: Conteo de casos por criterio diagnóstico de asfixia intraparto en los 552 registros originales del CTU-UHB.

Criterio	N casos	%
pH < 7,05 (solo pH severo)	40	7,2
pH < 7,10 (pH moderado–severo)	56	10,1
Apgar 1 min < 7	68	12,3
Apgar 5 min < 7	19	3,4
Apgar 1 min < 4 (severo)	17	3,1
Apgar 5 min < 4 (severo)	0	0,0
ACOG: pH < 7,00 + Apgar5 < 7	3	0,5
pH < 7,05 + Apgar5 < 7	7	1,3
pH < 7,10 + Apgar1 < 7 (amplio)	23	4,2
Gold standard: pH < 7,05 + Apgar5 < 7 + HIE/NICU	0	0,0

La Figura 2-1 ilustra el análisis completo de outcomes. La categoría clínica combinada de los 552 registros reveló que el 90,4 % de los casos presentan un outcome normal, el 6,0 % corresponden a acidosis sin depresión clínica relevante (pH alterado pero Apgar 5 recuperado), el 2,2 % son casos de depresión neonatal sin acidosis severa, el 1,3 % corresponden a asfixia confirmada (pH < 7,05 +

Apgar5 < 7) y el 0,2% son casos borderline ($\text{pH} < 7,10 + \text{Apgar1} < 7$). El conjunto de outcomes neonatales está completo en los 552 registros, por lo que no hubo casos descartados por falta de datos en esta etapa.




Figura 2-1: Análisis de outcomes de asfixia intraparto en los 552 registros originales del CTU-UHB. Panel superior izquierdo: categorías clínicas combinadas. Panel superior central y derecho: dispersión pH vs. Apgar5 y pH vs. Apgar1, respectivamente, con umbrales diagnósticos superpuestos. Panel inferior: distribución de pH umbilical, distribución comparada de Apgar1 y Apgar5, y conteo por criterio diagnóstico.

El análisis de la puntuación Apgar reveló un patrón clínicamente esperado, ya que la gran mayoría de los recién nacidos con $\text{Apgar1} < 7$ se recuperaron a un $\text{Apgar5} \geq 7$ (considerando que solo 18 de los 68 casos con Apgar1 deprimido mantuvieron un $\text{Apgar5} < 7$), lo que refleja la capacidad compensatoria del neonato en la mayoría de los casos. Esta disociación entre Apgar1 y Apgar5 es relevante para el modelamiento, ya que utilizar únicamente el Apgar5 como etiqueta subestimaría el compromiso fetal real observado durante el trabajo de parto, como ilustra la Figura 2-2.




Figura 2-2: Análisis de la puntuación Apgar en los 552 registros originales del CTU-UHB. Panel izquierdo: distribución comparada de Apgar al minuto 1 y al minuto 5. Panel central: conteo de casos por criterio basado en Apgar. Panel derecho: dispersión Apgar1 vs. Apgar5, con casos con algún Apgar < 7 resaltados en rojo.

2.2.2. Definición del outcome compuesto (Estrategia B)

Con base en el análisis anterior y en la necesidad de contar con una prevalencia de positivos que permita un entrenamiento estable de los modelos, se adoptó la Estrategia B como label principal:

$$\text{target} = 1 \Leftrightarrow \text{pH} < 7,10 \vee \text{Apgar5} < 7 \quad (1)$$

Esta definición captura tanto el compromiso bioquímico (acidosis moderada) como el clínico (depresión neonatal), resultando en una prevalencia de positivos de 12,1 % sobre el total de 552 registros (67 casos positivos), lo que permite un entrenamiento más estable que los criterios más estrictos (prevalencias inferiores al 1,5 %). El criterio de ingreso a UCI neonatal (NICU_days) se descartó del label porque su valor es cero en los 552 registros de la cohorte CTU-UHB, de modo que no aporta ningún caso positivo adicional.

2.3. Análisis Exploratorio de la Señal CTG

La Figura 2-3 presenta el análisis exploratorio del dataset CTU-UHB sobre los registros originales y sintéticos. Los paneles superiores confirman que las distribuciones de pH, Apgar1 y Apgar5 en las series sintéticas replicaron fielmente las de los registros originales, validando la conservación de la metadata clínica. Los paneles centrales ilustran la separabilidad limitada entre casos positivos y negativos en el espacio bidimensional pH–Apgar, lo que motiva el enfoque multivariado con características extraídas de la señal. El panel derecho inferior muestra que el 95,7 % de los partos en el CTU-UHB fueron vaginales espontáneos, lo que condiciona el perfil de riesgo de la cohorte.





Figura 2-3: Análisis exploratorio del dataset CTU-UHB (originales y sintéticos). Fila superior: distribuciones de pH umbilical, Apgar1 y Apgar5 en registros originales (azul) y sintéticos (rojo). Fila central: dispersión pH vs. Apgar1 y Apgar5, FHR media por grupo Apgar1. Fila inferior: criterios de asfixia ACOG, factores de riesgo maternos y distribución de tipo de parto.

El análisis piloto sobre el registro 1001 del dataset CTU-UHB ilustró la complejidad del problema de modelado. Se trata de una paciente de 32 años con diabetes materna y rotura prematura de membranas, con parto vaginal espontáneo. La señal de FHR muestra una línea de base estable en torno a 140–150 lpm con oscilaciones reducidas, compatible visualmente con un trazado categoría I según FIGO (Ayres-de-Campos et al., 2015). Sin embargo, el outcome bioquímico revela acidosis mixta: pH 7,14 (por debajo del umbral normal $\geq 7,20$), exceso de base de $-10,5$ mEq/L y pCO_2 de 7,7 kPa, con un Apgar1 deprimido (6 puntos) pero recuperación satisfactoria a los 5 minutos (Apgar5 = 8).

Figura 2-4: Serie de tiempo del registro 1001 del dataset CTU-UHB. Panel superior: frecuencia cardíaca fetal (FHR) en lpm. Panel inferior: actividad uterina (UC) en mmHg. Señales muestreadas a 4 Hz. Adaptado de Chudácek et al. (2014).



Esta disociación entre la apariencia visual del trazado y el outcome bioquímico refuerza la motivación central del proyecto: la interpretación visual tradicional puede no capturar patrones sutiles de compromiso fetal progresivo que sí son detectables mediante análisis cuantitativo de la señal.

3. AMPLIACIÓN DE LA MUESTRA

3.1. Motivación y elección del modelo de bootstrap

Con 552 registros disponibles y una prevalencia de positivos del 12,1 %, el dataset presenta dos limitaciones para el entrenamiento de modelos: el número absoluto de casos positivos ($n \approx 67$) es bajo para modelos no lineales, y la clase mayoritaria tiene una representación más de 7 veces mayor que la minoritaria (ratio $\approx 7,3:1$). Para mitigar ambas limitaciones sin recurrir a sintéticos que alteren la etiqueta clínica, se adoptó un enfoque de remuestreo estadístico mediante *Stationary Bootstrap* (Politis & Romano, 1994).

Se evaluaron cuatro estrategias de generación de datos sintéticos: Block Bootstrap clásico, *Moving Block Bootstrap* (MBB) (Künsch, 1989), *Stationary Bootstrap* (SB) y *Jitter + Time Warping* como método de referencia de aumentación clásica en aprendizaje automático. El criterio de selección consideró dos requisitos fundamentales para señales cardiocográficas: preservar la estructura de autocorrelación de la FHR y mantener el acoplamiento temporal entre ambos canales de la señal (FHR y UC). La comparación cuantitativa de fidelidad entre estrategias se presenta en la Tabla 3-1.

Tabla 3-1: Comparación de métricas de fidelidad estadística entre las cuatro estrategias de remuestreo evaluadas. El Stationary Bootstrap y el Jitter + Time Warping superan los cuatro umbrales; únicamente el Stationary Bootstrap garantiza la estacionariedad débil de las series resultantes.

Estrategia	KS-stat	Wasserstein (bpm)	ACF r	PSD r
<i>Block Bootstrap</i>	0,0015	0,082	0,976	0,997
<i>Moving Block Bootstrap</i>	0,0022	0,068	0,977	0,997
<i>Stationary Bootstrap</i>	0,0023	0,119	0,992	0,999
<i>Jitter + Time Warping</i>	0,0064	0,210	0,995	0,994
Umbral literatura	$< 0,05$	$< 1,0$	$> 0,98$	$> 0,95$

El Stationary Bootstrap fue seleccionado sobre Jitter + Time Warping porque, aunque ambos superan los cuatro umbrales de fidelidad, el SB garantiza matemáticamente que las series resultantes sean débilmente estacionarias (Politis & Romano, 1994), gracias a su longitud de bloque con distribución geométrica de media b^* . El Jitter + Time Warping introduce distorsiones morfológicas que pueden alterar implícitamente la etiqueta clínica de las desaceleraciones, al desplazar temporalmente los valles de FHR respecto a los picos de UC. El Block Bootstrap y MBB, en cambio, no superan el umbral de ACF ($0,976-0,977 < 0,98$) y generan discontinuidades en los bordes de bloque al usar longitud fija.

3.2. Bootstrap multivariado sincronizado

La señal CTG es bivariada: FHR y UC están fisiológicamente acopladas, ya que una contracción uterina desencadena una respuesta en la frecuencia cardíaca fetal segundos después. Aplicar el bootstrap de forma independiente a cada canal destruiría esta relación, generando pares (FHR, UC) fisiológicamente incoherentes.

Se implementó una extensión multivariada sincronizada del Stationary Bootstrap: un único vector de índices de bloques es generado y aplicado simultáneamente a FHR y UC, de modo que cada instante temporal sintético corresponde al mismo instante en el registro original. Esta sincronización fue validada mediante la función de correlación cruzada $FHR \leftrightarrow UC$, que arrojó un coeficiente de Pearson $r = 0,9971$ entre las curvas de correlación cruzada media de los registros originales y sintéticos, superando el umbral de referencia de 0,90.

La Figura 3-1 muestra cuatro pares de trazados FHR originales (azul) y sintéticos (rojo) para el Stationary Bootstrap. Se aprecia que las series sintéticas preservan la morfología general, la amplitud y la escala temporal de los patrones de la señal original, sin introducir discontinuidades ni distorsiones morfológicas apreciables.




Figura 3-1: Trazados CTG originales (azul) versus sintéticos (rojo) para cuatro registros representativos generados con Stationary Bootstrap. Las series sintéticas reproducen la morfología, amplitud y dinámica temporal de las señales originales sin introducir discontinuidades artificiales.

3.3. Filtrado de registros elegibles

Previo al proceso de bootstrap, se aplicaron criterios de calidad de señal sobre los 552 registros disponibles, en línea con las prácticas de preprocesamiento del análisis computarizado del CTG (Georgieva et al., 2017): se excluyeron los registros con más de un 30 % de valores faltantes en la señal FHR y aquellos con duración inferior a 30 minutos. Estos criterios resultaron en la exclusión de 65 registros, dejando 487 registros elegibles para el proceso de bootstrap.

3.4. Selección del tamaño de bloque b^*

El tamaño de bloque b^* determina la escala temporal de dependencia que el bootstrap preserva. En registros CTG, los patrones clínicamente relevantes para la detección de asfixia, como las desaceleraciones, la variabilidad de largo plazo y los patrones de recuperación, operan en escalas

temporales de 1 a 5 minutos (Ayres-de-Campos et al., 2015). Con base en este criterio clínico, se estableció $b^* = 300$ s como tamaño de bloque, con un mínimo de 60 s correspondiente a la ventana estándar de análisis de variabilidad a largo plazo.

Un diagnóstico mediante la función de autocorrelación (ACF) confirmó que este valor preserva adecuadamente la estructura de dependencia para desfases menores a 30 s (sesgo $< 0,05$), mientras que para desfases superiores a 120 s el sesgo es de 0,13–0,15, limitación inherente a los métodos de bootstrap por bloques para señales con memoria larga. El tiempo de memoria mediano de las series sintéticas fue de 31 s frente a 47 s en los registros originales, como resume la Figura 3-2.




Figura 3-2: Diagnóstico de autocorrelación (ACF) del Stationary Bootstrap. *Izquierda*: curva ACF media ± 1 desviación estándar para registros originales (azul) y sintéticos (rojo). *Centro*: sesgo punto a punto $ACF_{orig} - ACF_{synt}$ por desfase. *Derecha*: distribución del tiempo de memoria por registro.

3.5. Determinación del número de réplicas

El número de réplicas sintéticas N por registro fue determinado mediante un criterio de convergencia del estimador bootstrap (Efron & Tibshirani, 1993): se generaron réplicas de forma incremental hasta que la variación absoluta de la desviación estándar de la media de FHR entre iteraciones consecutivas fue inferior a $\Delta\sigma < 0,01$. La convergencia se alcanzó en $N = 2$ réplicas por registro ($\Delta\sigma = 0,0016$). El dataset de entrenamiento resultante contiene **974 series sintéticas**, elevando el pool de registros elegibles aumentados a **1.461** (487 originales elegibles + 974 sintéticos). Los 65 registros excluidos por calidad de señal siguen presentes en la partición original de 552 y contribuyen a las ventanas de test, pero no generan sintéticos. La proporción de casos positivos se preservó exactamente en 12,1 % tanto en originales como en sintéticas, dado que la metadata clínica es heredada directamente del registro de origen.

3.6. Validación de fidelidad

La calidad de las series sintéticas fue evaluada mediante cinco métricas de fidelidad estadística comparando 100 pares de registros originales y sintéticos:

- **Distribución marginal FHR:** test de Kolmogorov-Smirnov $D = 0,002$ ($< 0,05$) y distancia de Wasserstein $W = 0,12$ bpm ($< 1,0$ bpm).
- **Distribución marginal UC:** $D = 0,003$ y $W = 0,14$.
- **Estructura de autocorrelación FHR:** correlación de Pearson entre curvas ACF media $r = 0,992$ ($> 0,98$).
- **Contenido espectral FHR:** correlación log-PSD $r = 0,999$ ($> 0,95$).
- **Acoplamiento FHR↔UC:** correlación entre funciones de correlación cruzada media $r = 0,997$ ($> 0,90$).

Las cinco métricas superaron los umbrales establecidos en la literatura, validando que las series sintéticas reproducen la distribución marginal, la estructura temporal y el acoplamiento fisiológico entre señales (Figuras 3-3 y 3-4).




Figura 3-3: Validación de fidelidad del Stationary Bootstrap. De izquierda a derecha y de arriba a abajo: histogramas de distribución marginal FHR y UC, función de autocorrelación media FHR, densidad espectral de potencia FHR (escala logarítmica), función de correlación cruzada FHR↔UC, y tabla resumen de métricas con umbrales de referencia.




Figura 3-4: Reporte de fidelidad del Stationary Bootstrap. Comparación distribucional detallada entre registros originales y sintéticos en las dimensiones de distribución marginal, autocorrelación y densidad espectral de potencia, confirmando la preservación de todas las propiedades estadísticas clave de la señal CTG.

4. EXTRACCIÓN DE CARACTERÍSTICAS

4.1. Pipeline de extracción

La representación de las señales cardiotocográficas en términos de características tabulares es el paso crítico que conecta la señal cruda con los modelos de clasificación. Se implementó un pipeline limpio (`pipeline_01_feature_engineering.py`) que aplica un protocolo de cuatro pasos a cada par de señales (FHR, UC): (1) interpolación lineal de muestras inválidas con detección de ceros, valores fuera de rango fisiológico (< 50 o > 240 lpm para FHR; < 0 o > 150 mmHg para UC) y NaN; (2) estimación de la línea de base de FHR mediante filtro de mediana en dos pasadas (ventanas de 15 s y 120 s); (3) detección de aceleraciones y desaceleraciones sobre el residuo FHR–baseline; y (4) cálculo de métricas de complejidad no lineal sobre la señal submuestreada a 1 Hz.

Una consideración metodológica fundamental de esta etapa fue la **exclusión de variables post-outcome** del conjunto de predictores. Variables como el tipo de parto (`Deliv_type`), la duración de la segunda etapa, el diagnóstico de falta de progreso y los propios outcomes bioquímicos (pH, Apgar) fueron explícitamente prohibidas del dataset de modelamiento, ya que solo son conocidas al concluir el trabajo de parto y no estarían disponibles en un sistema de alerta en tiempo real. Este control evita una forma de fuga de información que afectó el análisis exploratorio previo.

La extracción se realizó sobre ventanas deslizantes de 20 minutos con paso de 5 minutos, generando múltiples observaciones por registro. Las ventanas con más del 30 % de muestras inválidas fueron descartadas. Este paradigma de ventanas deslizantes permite simular la operación de un sistema de alerta en tiempo real que actualiza su evaluación cada 5 minutos durante el trabajo de parto.

4.2. Características extraídas

El conjunto de características estáticas de ventana totaliza 35 variables, organizadas en tres categorías de señal (27) más los metadatos clínicos (8), como detalla la enumeración siguiente.

Categoría 1: Parámetros temporales y morfológicos (19). Se agrupan en cinco bloques: (i) calidad de señal: porcentaje de muestras inválidas en FHR y en UC (2); (ii) línea de base de FHR: media, mediana, desviación estándar y pendiente en bpm/min (4); (iii) aceleraciones: conteo, amplitud media y duración media (3); (iv) desaceleraciones: conteo total, conteo de tempranas, tardías y variables según el desfase respecto al pico de la contracción uterina más cercana, más amplitud media y duración media (6); y (v) acoplamiento uterino: desfase medio y mediano entre desaceleración y contracción, conteo de contracciones uterinas detectadas y número de ventanas válidas de variabilidad a largo plazo (4).

Categoría 2: Variabilidad a largo plazo (LTV) (2). Amplitud media y mediana de oscilación de la FHR en ventanas de 60 segundos (percentil 95 menos percentil 5 del residuo FHR—baseline), excluyendo ventanas con contenido de desaceleraciones superior al 10 %.

Categoría 3: Complejidad no lineal (6). Se aplican tres métodos de complejidad no lineal sobre la señal FHR submuestreada a 1 Hz, generando en total seis características numéricas:

- **Entropía Aproximada (ApEn):** mide la regularidad de la señal mediante vecindarios en el espacio de fase, con tolerancia $r = 0,2\sigma$ y orden $m = 2$.
- **Entropía Muestral (SampEn):** variante de ApEn que excluye las auto-comparaciones, más robusta ante cambios de longitud de señal.
- **Análisis de Fluctuación sin Tendencia (DFA):** estima el exponente de escala α mediante regresión log-log de las fluctuaciones cuadráticas medias por segmento. Produce cuatro características: el exponente global α , el exponente de corto plazo α_{short} , el exponente de largo plazo α_{long} y el intercepto de la regresión.

Metadatos clínicos (8). Adicionalmente, se incluyen variables clínicas disponibles al inicio del trabajo de parto: edad materna, gravidez, paridad, sexo fetal, peso al nacer, semanas de gestación y dos comorbilidades maternas (Diabetes y Pirexia). Sumando las tres categorías de señal ($19+2+6 = 27$) y estos metadatos (8) se obtienen las 35 características estáticas de ventana.

4.3. Características longitudinales para el modelo secuencial

Para los modelos secuenciales (XGBoost y CatBoost), se añadieron seis características adicionales de tendencia longitudinal que capturan la dinámica entre ventanas consecutivas, completando las 41 características en total que alimentan los modelos de Fase 3:

- **delta_baseline_std_bpm:** cambio en la desviación estándar de la línea de base entre la ventana actual y la de dos pasos previos.
- **delta_sampen:** cambio en la entropía muestral entre ventanas.
- **fhr_std_falling_streak:** número de ventanas consecutivas con descenso continuo de la desviación estándar de FHR.
- **fhr_sampen_falling_streak:** número de ventanas consecutivas con descenso continuo de SampEn.
- **slope_sampen_30min:** pendiente lineal de la entropía muestral en las últimas 6 ventanas (30 minutos).

- **slope_baseline_mean_30min:** pendiente lineal de la media de la línea de base en las últimas 6 ventanas.

Estas características convierten el clasificador de ventanas estáticas en un sistema con memoria longitudinal, capaz de detectar tendencias de deterioro que un modelo sin contexto temporal no puede capturar. Las métricas de complejidad no lineal se han reportado como sensibles a estados de compromiso fetal incluso cuando los parámetros visuales tradicionales no muestran alteraciones: una FHR con SampEn decreciente refleja reducción progresiva de la complejidad e irregularidad de la señal, indicador de pérdida de la autonomía regulatoria del sistema cardiovascular fetal asociada a hipoxia (Richman & Moorman, 2000; Spilka et al., 2012).

5. MODELAMIENTO Y RESULTADOS

5.1. Diseño del experimento y control de fugas de información

El control de fugas de información (*data leakage*) fue una consideración central en el diseño del experimento, dado que la naturaleza temporal de las señales, la generación de ventanas múltiples por paciente y la presencia de datos sintéticos introducen riesgos específicos.

La validación del desempeño se realizó mediante validación cruzada anidada a nivel de paciente. En el bucle externo se empleó un StratifiedKFold estratificado por paciente, de modo que ningún paciente aporta ventanas al conjunto de entrenamiento y al de test de un mismo pliegue de forma simultánea. La estratificación mantiene además cada pliegue balanceado en el número de pacientes positivos (19 pacientes positivos por pliegue), evitando que la varianza entre pliegues quede dominada por el reparto desigual de una clase tan minoritaria. Las series sintéticas fueron generadas después de la partición y se asignaron exclusivamente a los pliegues de entrenamiento, asociándolas mediante el campo `source_record` al registro de origen, de modo que ninguna ventana sintética derivada de un paciente de test pueda contaminar el ajuste.

El ajuste de hiperparámetros se realizó en un bucle interno de validación cruzada, también agrupado por paciente, optimizando el AUROC en validación y no el AUPRC. Si bien el AUPRC es la métrica más informativa para evaluar clasificadores bajo fuerte desbalance de clases, y por ello se reporta (Saito & Rehmsmeier, 2015), con apenas siete a ocho pacientes positivos por pliegue interno su estimación es demasiado inestable para guiar la selección de hiperparámetros, que termina dominada por el ruido de la partición antes que por señal genuina; por ello se optimizó el AUROC, más estable en este régimen.

La segunda fuente de fuga controlada fue el *leakage* temporal: todas las características se calcularon usando exclusivamente información disponible hasta el instante t de la ventana evaluada, sin acceso a datos posteriores. Las características longitudinales (tendencias) se computaron estrictamente hacia atrás (*look-back*).

El umbral de decisión de cada modelo se calibró sobre las predicciones fuera de muestra (*out-of-fold*) del bucle interno de validación, seleccionando el umbral más alto que garantiza una sensibilidad mínima del 75 % sin usar información del pliegue de test. Los valores de sensibilidad reportados sobre cada pliegue externo deben interpretarse como resultado observado y no como garantía del umbral. Esta calibración prioriza la detección de casos positivos, coherente con el contexto clínico donde un falso negativo tiene consecuencias más graves que un falso positivo.

Por último, la incertidumbre de todas las métricas se cuantificó mediante intervalos de confianza por *bootstrap* a nivel de paciente, remuestreando con reemplazo la unidad estadísticamente

independiente del problema, que es el paciente y no la ventana (Kaufman et al., 2012; Saeb et al., 2017). La comparación entre modelos se realizó sobre la distribución *bootstrap* pareada del Δ AUROC, un sustituto no paramétrico del test de DeLong et al. (1988) para AUCs correlacionadas.

5.2. Anclaje temporal del label

Un problema metodológico de raíz, identificado en la revisión del pipeline, condicionaba la interpretación de todos los resultados previos. En la construcción original del label, todas las ventanas extraídas de un paciente con outcome adverso heredaban la etiqueta positiva, incluidas las tempranas y clínicamente tranquilas, muy anteriores a cualquier signo de deterioro. Como esas ventanas etiquetadas como positivas no contienen señal de compromiso, el modelo no podía separarlas por la morfología del trazado y aprendía a distinguir a los pacientes adversos por su demografía basal (edad, peso, semanas de gestación), constante en todas sus ventanas. El poder predictivo aparente descansaba entonces sobre el *prior* demográfico y no sobre la señal CTG, que es justamente lo que el proyecto se propone explotar.

La corrección consiste en anclar temporalmente la etiqueta al horizonte de anticipación clínica. Una ventana se etiqueta como positiva si y solo si el paciente es adverso y su tiempo hasta el parto satisface $\text{time_to_birth} \leq h$, con $h = 30$ minutos; todas las ventanas de un paciente no adverso son negativas; y las ventanas de un paciente adverso con $\text{time_to_birth} > h$ se excluyen del conjunto por corresponder a un régimen pre-onset ambiguo, en el que no hay garantía de que la señal ya refleje el compromiso.

El aporte relativo de la señal frente a la demografía se cuantificó mediante una ablación de la regresión logística, contrastando un modelo que usa solo variables demográficas basales contra uno que usa solo características de la señal CTG, con AUROC a nivel de paciente (Tabla 5-1). En ambas condiciones la señal CTG concentra el poder predictivo (AUROC en torno a 0,63–0,65), muy por encima de la demografía basal, que queda cerca del azar (0,51–0,53). Este resultado se sostiene con y sin anclaje, lo que indica que fueron el control de fugas y la validación cruzada estratificada por paciente los que impidieron que el modelo se apoyara en variables demográficas constantes. El anclaje temporal cumple un rol complementario y distinto: no busca ni produce una mejora de discriminación, sino que define correctamente la tarea de alerta temprana, etiquetando como positiva únicamente la ventana cercana al desenlace en un paciente adverso y evitando el ruido de rotular como positivas ventanas tempranas sin compromiso. Es esa definición la que da sentido clínico a las métricas de anticipación reportadas más adelante.

Tabla 5-1: Ablación del efecto del anclaje temporal del label sobre la regresión logística. AUROC a nivel de paciente, contrastando un modelo con solo variables demográficas contra uno con solo características de la señal CTG.

Configuración	Solo demografía	Solo señal CTG
Sin anclaje	0,508	0,647
Con anclaje ($h = 30$ min)	0,526	0,628

5.3. Fase 1: Evaluación univariada sobre ventanas

Nota metodológica: las Fases 1 y 2 son exploratorias y se realizaron sobre una partición única de test previa a la adopción del anclaje temporal del label y de la validación cruzada anidada por paciente. Sus métricas de alerta temprana (del orden de 45 minutos) corresponden a ese esquema y no deben compararse directamente con las de la Fase 3, que son las definitivas; se conservan por su valor descriptivo del poder individual de las características.

El objetivo de esta fase fue cuantificar el poder predictivo individual de cada característica en el paradigma de ventanas deslizantes, mediante regresión logística simple con validación cruzada agrupada por paciente. Los resultados de las 10 características más informativas se presentan en la Tabla 5-2.

Tabla 5-2: Análisis univariado de las 10 características más informativas para la predicción del outcome compuesto (Estrategia B) sobre ventanas de 20 minutos. Resultados en validación cruzada de 5 pliegues agrupada por paciente. OR por desviación estándar de la variable.

Característica	AUROC CV	OR	IC 95 %	p-valor
fhr_baseline_std_bpm	0,598	1,337	[1,116 – 1,601]	0,002
ltv_mean_amp_bpm	0,575	1,251	[1,021 – 1,531]	0,030
fhr_invalid_pct	0,564	1,237	[1,005 – 1,523]	0,045
ltv_median_amp_bpm	0,563	1,207	[0,997 – 1,460]	0,053
Sex	0,561	0,786	[0,558 – 1,109]	0,170
accelerations_count	0,549	1,214	[1,010 – 1,458]	0,039
accelerations_mean_amp_bpm	0,546	1,167	[0,961 – 1,418]	0,119
accelerations_mean_duration_s	0,544	1,180	[0,968 – 1,438]	0,101
Age	0,544	1,271	[0,881 – 1,832]	0,199
slope_sampen_30min	0,538	0,869	[0,770 – 0,980]	0,022

Los AUROCs univariados sobre ventanas son notablemente más modestos que los obtenidos en análisis sobre registros completos (el mejor alcanza 0,598 vs. 0,716 en el análisis de registro

completo). Esta reducción era esperable: las ventanas de 20 minutos extraídas en distintos momentos del trabajo de parto incluyen tanto instantes de alto riesgo como instantes tranquilos del mismo paciente positivo, lo que aumenta la variabilidad del target aparente y dificulta la separabilidad. La ventaja de este paradigma es que permite la evaluación longitudinal en tiempo real, que es el objetivo clínico final.

La variable más informativa, `fhr_baseline_std_bpm` (OR=1,337), mantiene su liderazgo respecto al análisis de registro completo. Notablemente, las métricas de variabilidad a largo plazo (`ltv_mean_amp_bpm`, `ltv_median_amp_bpm`) emergen como la segunda y cuarta características más importantes, coherente con la fisiopatología de la hipoxia que reduce la variabilidad cardíaca fetal. La característica longitudinal `slope_sampen_30min` (OR=0,869, $p = 0,022$) también resulta significativa, capturando la tendencia decreciente de la complejidad en los 30 minutos previos a la ventana actual.

5.4. Fase 2: Selección multivariada Forward sobre ventanas

Se construyeron dos modelos de regresión logística multivariada mediante selección iterativa *Forward* sobre el conjunto de ventanas de entrenamiento: el modelo AIC maximiza la reducción del criterio de Akaike (penalización más laxa, tolerando más variables), mientras que el modelo BIC aplica una penalización más severa favoreciendo la parsimonia. Ambos modelos se ajustaron sobre el conjunto de entrenamiento estandarizado (mediana-imputado y centrado-escalado).

5.4.1. Modelo AIC: 23 variables con tendencias temporales

El modelo AIC seleccionó 23 variables en selección progresiva, con un criterio AIC final de 2.105,2 (vs. 2.258,5 del modelo nulo). Las primeras cinco variables en entrar por orden de reducción de criterio fueron: (1) `fhr_baseline_std_bpm` ($\Delta AIC=30,1$), (2) Age ($\Delta AIC=17,4$), (3) Parity ($\Delta AIC=16,9$), (4) Sex ($\Delta AIC=17,4$), (5) Diabetes ($\Delta AIC=7,2$).

El modelo AIC incorporó cuatro de las seis características longitudinales: `slope_sampen_30min` (paso 12), `fhr_sampen_falling_streak` (paso 17), `delta_sampen` (paso 18) y `delta_baseline_std_bpm` (paso 23). La inclusión de estas tendencias en el modelo lineal confirma que la dinámica temporal entre ventanas aporta información predictiva adicional a los valores estáticos de cada ventana.

5.4.2. Modelo BIC: 5 variables parsimoniosas

El modelo BIC seleccionó exclusivamente 5 variables, `fhr_baseline_std_bpm`, Age, Parity, Sex y Diabetes, con un criterio BIC final de 2.206,1. Los coeficientes e interpretaciones se presen-

tan en la Tabla 5-3.

Tabla 5-3: Coeficientes del modelo multivariado BIC sobre ventanas (5 variables). OR por desviación estándar de la variable estandarizada.

Variable	Coeficiente	OR	p-valor
Intercepto	-2,235	0,107	< 0,001
fhr_baseline_std_bpm	+0,285	1,330	0,002
Age	+0,398	1,489	0,058
Parity	-0,327	0,721	0,127
Sex	-0,243	0,785	0,176
Diabetes	-0,204	0,815	0,247

El modelo BIC retiene principalmente variables clínico-demográficas disponibles al inicio del trabajo de parto. Cabe notar que únicamente fhr_baseline_std_bpm alcanza significancia estadística individual ($p = 0,002$); las demás variables (Age $p = 0,058$, Parity $p = 0,127$, Sex $p = 0,176$, Diabetes $p = 0,247$) fueron retenidas por reducir el BIC como conjunto, no por significancia individual. La edad materna y la paridad son factores de riesgo obstétrico reconocidos clínicamente, lo que justifica su retención en el modelo a pesar de los p-valores marginales en este tamaño de muestra. La diabetes materna muestra un OR protector (0,815), posiblemente reflejando el monitoreo más estricto al que son sometidas estas pacientes en la cohorte CTU-UHB.

5.4.3. Comparación de desempeño en la Fase 2

Los modelos AIC y BIC se evaluaron en el conjunto de test, calculando métricas de alerta temprana a nivel de paciente para todos los 166 pacientes de test. Los resultados se resumen en la Tabla 5-4.

Tabla 5-4: Comparación de modelos AIC y BIC sobre ventanas de test (166 pacientes). *Recall Pcte.*: proporción de pacientes positivos con al menos una alerta correcta. *EW*: tiempo mediano de alerta anticipada en minutos.

Modelo	N Vars	AUROC	AUPRC	Sensib.	Recall Pcte.	EW (min)
Forward AIC	23	0,602	0,179	0,713	0,95	45,0
Forward BIC	5	0,604	0,203	0,708	0,90	46,8

El modelo BIC (5 variables) logra un AUROC marginalmente superior (0,604 vs. 0,602) y mayor AUPRC (0,203 vs. 0,179), mientras que el AIC (23 variables) supera levemente en Patient Recall (95 % vs. 90 %). La diferencia de AUROC entre modelos es mínima, sugiriendo que las 18

variables adicionales del AIC aportan poco poder discriminativo neto. Ambos modelos logran alertar al menos un 90 % de los pacientes positivos con una mediana de 45–47 minutos de anticipación, lo cual es clínicamente significativo.

5.5. Fase 3: Modelos secuenciales avanzados (XGBoost y CatBoost)

En la fase final se entrenaron cuatro variantes de modelos basados en árboles de decisión potenciados: XGBoost y CatBoost, cada uno en dos configuraciones de datos de entrenamiento (solo datos reales y datos reales más sintéticos). Todos los modelos utilizan las 41 características en total (35 estáticas de ventana más 6 de tendencia longitudinal), operando sobre el mismo paradigma de ventanas deslizantes de 20 minutos.

5.5.1. Hiperparámetros optimizados

La búsqueda de hiperparámetros se realizó mediante RandomizedSearchCV de 12 iteraciones sobre la validación cruzada interna agrupada por paciente, optimizando el AUROC en validación (véase la discusión sobre AUROC frente a AUPRC en el diseño del experimento). Los mejores hiperparámetros encontrados se resumen en la Tabla 5-5.

Tabla 5-5: Mejores hiperparámetros de la búsqueda aleatoria en la fase exploratoria (partición única, cuatro configuraciones real-only/real+sintético). Los modelos definitivos se reajustaron dentro del CV anidado por paciente; estos valores se muestran a título ilustrativo del orden de magnitud de los hiperparámetros.

Modelo	Hiperparámetros
XGBoost real-only	max_depth=3, lr=0,03, n_estimators=300, subsample=0,7, colsample_bytree=0,7, min_child_weight=5, reg_lambda=1,0, scale_pos_weight=2,87
CatBoost real-only	depth=3, lr=0,03, iterations=500, l2_leaf_reg=10,0, random_strength=2,0
XGBoost real+sint.	max_depth=2, lr=0,05, n_estimators=300, subsample=0,7, colsample_bytree=1,0, min_child_weight=5, reg_lambda=10,0, scale_pos_weight=1,0
CatBoost real+sint.	depth=3, lr=0,1, iterations=100, l2_leaf_reg=1,0, random_strength=0,5

El parámetro `scale_pos_weight = 2,87` del XGBoost real-only fue encontrado como óptimo por la búsqueda aleatoria; su valor moderado, inferior al ratio de desbalance real del conjunto de

entrenamiento ($\approx 7,3$), refleja el trade-off entre sensibilidad y especificidad aprendido en validación cruzada. En contraste, el XGBoost real+sintético usa `scale_pos_weight = 1,0`, lo que indica que el aumento con datos sintéticos equilibró efectivamente la distribución de clases en el conjunto de entrenamiento aumentado.

5.5.2. Importancia de características

La Figura 5-1 muestra la importancia de características (ganancia media en los árboles) para el modelo XGBoost en la configuración exploratoria previa al anclaje del label. Las características demográficas Age y Weight_g lideran el ranking, seguidas de accelerations_count y fhr_baseline_std_bpm. Este predominio de la demografía es precisamente el artefacto que motivó el anclaje temporal del label descrito antes: con el label sin anclar, la ganancia se concentra en variables constantes por paciente. La característica longitudinal slope_sampen_30min aparece en la octava posición, lo que anticipa el aporte de la señal CTG que el anclaje posterior deja al descubierto.




Figura 5-1: Importancia de características (ganancia media) para el modelo XGBoost secuencial real-only (Fase 3). Las 25 características más importantes muestran un balance entre variables demográficas (Age, Weight_g, Gest_weeks), morfológicas (accelerations_count, fhr_baseline_std_bpm, fhr_baseline_median_bpm) y de complejidad no lineal (slope_sampen_30min, dfa_alpha). La característica longitudinal slope_sampen_30min figura entre las 10 más importantes.

5.5.3. Evaluación clínica de alerta temprana

Para traducir las probabilidades por ventana en una alerta clínica se aplica una regla de **persistencia**: un paciente se considera en alerta cuando acumula al menos dos ventanas consecutivas por sobre el umbral. Esta regla reemplaza al criterio anterior, que exigía que la última ventana estuviera en alerta y que, en la práctica, premiaba a un modelo siempre encendido. Sobre esta base se evalúan tres métricas clínicas adicionales a las estándar:

- **Patient Recall sostenido**: proporción de pacientes positivos que gatillan una alerta persistente en algún tramo de su registro.
- **Early Warning mediana (min)**: mediana del tiempo entre la primera alerta persistente y el parto, sobre los pacientes positivos con alerta.

- **Falsas alarmas por hora:** número de alertas persistentes gatilladas sobre pacientes sanos por hora de monitorización, como medida directa de la carga de alarmas.

Bajo la regla de persistencia, el sistema opera con una carga de aproximadamente 5,5 falsas alarmas por hora, y entre un 63 % y un 68 % de los pacientes sanos gatillan alguna alerta sostenida a lo largo de su registro. Esta cifra dimensiona la especificidad todavía limitada del enfoque en el paradigma de alerta temprana (Henry et al., 2015).

Los resultados de los modelos finales se presentan en la Tabla 5-6.

Tabla 5-6: Comparación de los modelos finales sobre el target compuesto, con anclaje temporal del label ($h = 30$ min) y validación cruzada anidada a nivel de paciente. Intervalos de confianza al 95 % por *bootstrap* a nivel de paciente ($B = 2000$; 57 pacientes positivos sobre 540).

Modelo	AUROC [IC95]	AUPRC
XGBoost	0,626 [0,550 – 0,701]	0,163
Regresión logística	0,605 [0,523 – 0,688]	0,176
CatBoost	0,544 [0,462 – 0,625]	0,129

El XGBoost es el modelo de mejor desempeño, con un AUROC de 0,626 a nivel de paciente. Supera a CatBoost de forma distinguible, ya que la diferencia pareada es de $\Delta\text{AUROC} \approx +0,08$ (IC95 [+0,02, +0,14]) y su intervalo de confianza *bootstrap* excluye el cero. Frente a la regresión logística, en cambio, queda estadísticamente empatado: los intervalos de confianza se solapan ampliamente y la comparación pareada no permite separarlos. Con un número de positivos tan pequeño ($n^+ = 57$), este ordenamiento debe leerse como evidencia exploratoria y no como un ranking definitivo de arquitecturas.

El Patient Recall sostenido se mantiene en un rango del 61 % al 76 % entre modelos, y la mediana de alerta anticipada, del orden de la media hora, constituye un margen clínicamente accionable para la toma de decisiones obstétricas.

Dado el número reducido de pacientes positivos (57 sobre 540), las métricas principales se acompañan de sus intervalos de confianza por *bootstrap* a nivel de paciente. La amplitud de estos intervalos implica que las diferencias de AUROC entre el XGBoost y la regresión logística no son estadísticamente distinguibles, y que el ordenamiento entre las mejores arquitecturas debe leerse como evidencia exploratoria antes que como una jerarquía definitiva. Confirmar estas diferencias requiere una validación sobre una cohorte mayor.

A nivel de caso individual, el perfil de riesgo del modelo no es monótono: la probabilidad estimada queda cerca del umbral durante buena parte del registro y solo se dispara de forma sostenida en el tramo final, lo que explica por qué la regla de persistencia (al menos dos ventanas consecutivas

en alerta) es necesaria para no gatillar con cada repunte aislado.

5.5.4. Análisis estratificado por endpoint

El endpoint compuesto agrega criterios de severidad muy dispar, por lo que un buen desempeño global no implica capacidad de detectar la asfixia grave. Para separar ambos planos se reevaluó el XGBoost sobre tres definiciones de outcome de exigencia creciente, con AUROC a nivel de paciente e intervalos de confianza por *bootstrap* (Tabla 5-7).

Tabla 5-7: Desempeño del XGBoost estratificado por definición de endpoint. AUROC a nivel de paciente con IC95 por *bootstrap*. La caída del desempeño al restringir la definición a la asfixia grave real es la observación central de este análisis.

Endpoint	Positivos	AUROC [IC95]
Compuesto ($\text{pH} < 7,10 \vee \text{Apgar5} < 7$)	57/540	0,626 [0,550 – 0,701]
Acidemia metabólica ($\text{pH} < 7,05 \wedge \text{BD} \geq 12$)	14/545	0,537 [0,374 – 0,708]
Asfixia severa ($\text{pH} < 7,00 \wedge \text{BD} \geq 12$)	9/545	0,412 [0,179 – 0,648]

La lectura es contundente. Sobre la asfixia severa real, que es el evento que el proyecto busca anticipar, el modelo cae al azar (AUROC 0,412, con un intervalo que cruza holgadamente 0,5). El desempeño del endpoint compuesto proviene de sus criterios más laxos, el umbral de pH moderado ($< 7,10$) y la depresión neonatal ($\text{Apgar5} < 7$), de modo que un buen desempeño sobre el compuesto no equivale a detectar la asfixia metabólica severa. Con apenas 9 casos severos, el intervalo es demasiado ancho para sostener cualquier afirmación, lo que subraya que el limitante es el tamaño muestral de los eventos graves.

5.6. Comparación global entre fases

El modelo final se entrena sobre una *whitelist* estricta de 41 predictores que excluye por construcción toda variable post-outcome (tipo de parto, duración de las etapas, diagnóstico de falta de progreso y los propios marcadores bioquímicos), disponibles solo al concluir el parto y por tanto inutilizables en un sistema de alerta en tiempo real. Este control cierra la vía de fuga de información que inflaba los resultados exploratorios previos (Kaufman et al., 2012).

Los modelos evaluados comparten el mismo paradigma de ventanas deslizantes, el mismo anclaje temporal del label y el mismo esquema de validación cruzada anidada por paciente, lo que permite una comparación directa. El XGBoost obtiene el AUROC más alto (0,626) y supera a CatBoost de forma distinguible, pero queda estadísticamente empatado con la regresión logística. Con 57 pacientes positivos, las diferencias entre las mejores arquitecturas caen dentro del ruido muestral,

de modo que ninguna domina de forma concluyente. La regresión logística, con su regularización implícita y su interpretabilidad directa, sigue siendo una referencia competitiva en este régimen de datos escasos.

La cobertura a nivel de paciente y el tiempo de alerta anticipada son similares entre modelos, con medianas de anticipación del orden de la media hora, un margen clínicamente accionable. El compromiso entre sensibilidad y carga de alarmas se mantiene en torno a las 5,5 falsas alarmas por hora bajo la regla de persistencia, sin que ningún modelo se despegue del resto en este eje.

6. DISCUSIÓN

6.1. Interpretación de los resultados

Los resultados de este trabajo muestran que es posible construir sistemas de alerta temprana para asfixia intraparto con un desempeño modesto, todavía insuficiente para un uso clínico autónomo, a partir de características extraídas de ventanas deslizantes de señales cardiotocográficas. Bajo la metodología corregida (control de fugas, validación estratificada por paciente y anclaje temporal del label), el mejor modelo honesto es el XGBoost, con un AUROC de 0,626 a nivel de paciente sustentado en la señal CTG y no en la demografía basal, aunque queda estadísticamente empatado con la regresión logística. El AUROC moderado, la baja especificidad y la caída al azar sobre la asfixia severa indican que se trata de un prototipo metodológico más que de un clasificador listo para despliegue.

La transición al paradigma de ventanas deslizantes, respecto al análisis de registro completo utilizado en la exploración preliminar, redujo los AUROCs individuales, aunque a cambio habilitó la evaluación de las métricas clínicas más relevantes, como el Patient Recall y el Early Warning. Por lo tanto, se trata de una decisión metodológica correcta para el objetivo final de un sistema de alerta en tiempo real.

El aporte del aumento sintético se midió con un bootstrap pareado a nivel de paciente, comparando cada modelo entrenado solo con reales frente a reales más sintéticas. Bajo la validación corregida, la diferencia no es distinguible del ruido en ninguno de los modelos (Δ AUROC entre $-0,02$ y $+0,00$, con intervalos de confianza que cruzan el cero). Este resultado es coherente con la teoría del bootstrap por bloques: el remuestreo preserva la estructura estadística de la señal (fidelidad validada en la Sección de ampliación de muestra), pero no genera información nueva sobre la frontera de decisión de la clase positiva, de modo que su efecto sobre la discriminación es, en el mejor de los casos, una reducción de varianza marginal. El aumento conserva por tanto su valor como herramienta de fidelidad y de balance de clases, no como fuente de mejora del AUROC en este régimen de datos. Su utilidad deberá reevaluarse sobre la cohorte de mayor tamaño del Hospital de Puerto Montt.

El análisis de importancia de características del modelo exploratorio sin anclaje mostraba a Age y Weight_g liderando el ranking de ganancia. En un modelo de ventana, estos valores son constantes para cada paciente y actúan como interceptos por paciente, permitiendo al modelo diferenciarse por riesgo basal antes de mirar la señal CTG. Ese comportamiento era un síntoma del régimen exploratorio previo, en el que la combinación de fugas de información y una validación cruzada estratificada por ventana permitía al modelo apoyarse en el riesgo basal demográfico. Bajo la metodología corregida (control de fugas, validación estratificada por paciente y anclaje temporal), el

poder predictivo descansa en la señal CTG y no en la demografía, que queda cerca del azar (ablación: solo demografía 0,51–0,53 frente a solo señal 0,63–0,65), que es el comportamiento buscado.

6.2. Limitaciones

Las siguientes limitaciones deben tenerse en cuenta al interpretar estos resultados:

- **Dataset de entrenamiento:** El CTU-UHB fue recopilado en un contexto europeo (República Checa, 1996–2010). La transferibilidad directa de los modelos a la cohorte chilena del Hospital de Puerto Montt deberá validarse empíricamente una vez disponibles los datos.
- **Prevalencia y tamaño muestral:** Con 57 pacientes positivos en el endpoint compuesto (y apenas 9 en la asfixia severa) sobre 540 pacientes, las estimaciones a nivel de paciente presentan intervalos de confianza amplios que hacen indistinguibles a los mejores modelos entre sí. Una validación sobre una cohorte mayor es necesaria para aportar certeza estadística y para poder afirmar algo sobre el endpoint severo.
- **Especificidad reducida:** La alta sensibilidad se logra al costo de una especificidad baja (del orden de 0,20 a nivel de ventana), lo que se traduce en aproximadamente 5,5 falsas alarmas por hora bajo la regla de persistencia, y en que entre un 63 % y un 68 % de los pacientes sanos gatillen alguna alerta sostenida. En un entorno clínico con alta carga de pacientes, esto podría traducirse en fatiga de alertas.
- **Sintéticos a nivel de registro completo:** Las series sintéticas generadas por el bootstrap corresponden a registros completos resampled, no a ventanas de 20 minutos. La ventana sintética extrae sus características del mismo registro remuestreado, lo que puede introducir correlaciones leves no presentes en ventanas de registros distintos.
- **Ausencia de SHAP:** La interpretación a nivel de predicción individual mediante valores SHAP fue identificada como prioridad pero no fue implementada en esta entrega. Queda pendiente como requisito para la adopción clínica.

6.3. Coherencia con la fisiopatología

Los patrones identificados por los modelos son en general coherentes con el conocimiento fisiopatológico de la asfixia intraparto. La importancia de `fhr_baseline_std_bpm` como predictor principal en todas las fases es consistente con la evidencia que identifica la reducción o el exceso atípico de variabilidad como marcadores de compromiso fetal (Ayres-de-Campos et al., 2015).

La característica longitudinal `slope_sampen_30min` (pendiente decreciente de la entropía muestral) aparece como predictor significativo tanto en el modelo logístico (paso 12 de selección

AIC) como en el XGBoost (octava posición por ganancia). Esto valida la hipótesis de que el deterioro de la complejidad de la señal cardíaca fetal en los 30 minutos previos al parto es un marcador temprano de compromiso, en línea con la literatura sobre pérdida de variabilidad a corto plazo asociada a hipoxia (Tarvonen et al., 2021).

Este hallazgo, sin embargo, debe leerse con cautela por un confound de calidad de señal. La entropía muestral covaría con el porcentaje de muestras inválidas de la FHR ($\rho = -0,42$), y su efecto predictivo no sobrevive al controlar por la calidad de la señal. En otras palabras, parte de la aparente pérdida de complejidad en los fetos comprometidos puede ser un artefacto de trazados más ruidosos o con más pérdida de señal, y no una reducción genuina de la irregularidad fisiológica, de modo que la interpretación clásica de la entropía como marcador de autonomía regulatoria fetal requiere descontar antes la calidad del registro (Pincus, 1991; Richman & Moorman, 2000). En la misma línea, se implementaron características validadas en la literatura reciente sobre CTG, como el área de deceleración (Cahill et al., 2018), la capacidad de deceleración por PRSA (Georgieva et al., 2014), la variabilidad a corto plazo (Kapaya et al., 2020) y la complejidad de Lempel-Ziv (Spilka et al., 2012). Medidas con bootstrap pareado a nivel de paciente, no mejoran el desempeño en esta cohorte ($\Delta\text{AUROC} = -0,016$), lo que se atribuye al sobreajuste con pocos positivos y a su redundancia con las características existentes. Quedan implementadas y citadas, pero excluidas de la whitelist de predictores, a la espera de reactivarse con la cohorte mayor del Hospital de Puerto Montt.

Las métricas LTV (`ltv_mean_amp_bpm`, `ltv_median_amp_bpm`) emergen como los predictores univariados más fuertes después de la variabilidad de la línea de base, en dirección esperada: una mayor amplitud de variabilidad a largo plazo en la ventana actual se asocia a mayor riesgo. Este resultado puede reflejar que patrones de variabilidad paradójicamente elevada (como la variabilidad sinusoidal) son marcadores de compromiso en ciertos subgrupos del CTU-UHB.

7. PLAN DE CONTINUIDAD

7.1. Integración de los datos del Hospital de Puerto Montt

La llegada de los datos del Hospital de Puerto Montt permitirá validar la transferibilidad del marco metodológico desarrollado. El pipeline de extracción de características implementado es directamente aplicable a los archivos exportados desde la central Philips, dada la compatibilidad de formato (señales FHR y UC a 4 Hz con metadatos clínicos). Los pasos inmediatos serán:

1. Aplicar el mismo protocolo de anonimización y control de calidad de señal sobre la base hospitalaria.
2. Extraer las 41 características en total (35 estáticas de ventana más 6 de tendencia longitudinal) sobre ventanas de 20 minutos con paso de 5 minutos.
3. Evaluar los modelos entrenados sobre CTU-UHB directamente sobre el conjunto hospitalario para cuantificar el sesgo de distribución entre cohortes.
4. Reentrenar los modelos con la cohorte chilena como principal y CTU-UHB como conjunto de preentrenamiento, si el volumen lo justifica.

7.2. Mejoras técnicas identificadas

Las siguientes mejoras técnicas han sido identificadas durante el desarrollo del proyecto:

- **Bootstrap a nivel de ventana:** Generar series sintéticas directamente como ventanas de 20 minutos en lugar de registros completos, para eliminar cualquier posible correlación estructural entre ventanas sintéticas de un mismo bootstrap.
- **Reducción de falsas alarmas:** El NNA actual de 7–8 alertas por positivo detectado podría reducirse mediante umbralización adaptativa o modelos de calibración post-hoc. Esto requiere un conjunto de calibración independiente.
- **Interpretabilidad SHAP:** Implementar la descomposición de predicciones individuales mediante valores SHAP, que permita al equipo clínico entender qué características motivaron cada alerta en cada ventana.
- **Calibración de probabilidades:** Aplicar calibración isotónica sobre las probabilidades de salida de los modelos para mejorar el Brier Score y habilitar umbrales interpretables como “probabilidad de riesgo”.

- **Arquitecturas de aprendizaje profundo:** Las redes convolucionales 1D y las redes recurrentes (LSTM) sobre la señal cruda son la extensión natural para volúmenes de datos superiores al disponible en esta etapa.

8. CONCLUSIONES

El presente informe documenta el desarrollo y validación de un marco algorítmico predictivo para la detección anticipada de asfixia intraparto, construido sobre el dataset público CTU-UHB ante la no disponibilidad de los datos del Hospital de Puerto Montt durante el período de desarrollo. Los resultados muestran que, con una metodología reproducible y libre de fugas de información, es posible construir un marco de alerta temprana honesto a partir de características extraídas de ventanas deslizantes de señales cardiotocográficas, si bien su desempeño con los datos actualmente disponibles es modesto y no alcanza el nivel requerido para un uso clínico autónomo.

El paradigma de **ventanas deslizantes de 20 minutos con paso de 5 minutos** es la contribución metodológica central de este trabajo: permite simular la operación de un sistema de alerta en tiempo real, evaluar métricas clínicas como el Patient Recall y el tiempo de alerta anticipada, e integrar características longitudinales de tendencia que capturan el deterioro progresivo de la señal. Este paradigma redujo los AUROCs individuales respecto al análisis de registro completo, como era esperable, pero habilitó una evaluación clínicamente más significativa.

El mejor modelo honesto es el **XGBoost**, con un AUROC de aproximadamente 0,63 a nivel de paciente, sustentado en la señal CTG y no en la demografía basal una vez corregidas las fugas de información y adoptada la validación estratificada por paciente, con el anclaje temporal del label definiendo la tarea de alerta temprana. Los modelos ensayados (XGBoost, regresión logística y CatBoost) son en gran parte indistinguibles entre sí dado el reducido número de positivos, por lo que el ordenamiento entre ellos constituye evidencia exploratoria y no un ranking definitivo de arquitecturas. Sobre el endpoint de asfixia severa real, el desempeño cae al azar (AUROC 0,41 con apenas 9 casos), lo que confirma que la discriminación del endpoint compuesto proviene de sus criterios más laxos (acidosis moderada y depresión neonatal) y que un buen desempeño sobre el compuesto no equivale a detectar la asfixia severa.

La regresión logística con selección Forward resulta competitiva pese a su simplicidad, quedando empatada con el XGBoost; el modelo BIC, con solo cinco variables, es la solución más parsimoniosa e interpretable. El anclaje temporal del label, la validación cruzada anidada a nivel de paciente, la exclusión estricta de variables post-outcome y los intervalos de confianza por *bootstrap* sobre el paciente son las correcciones metodológicas que hacen creíble este resultado.

El entregable de mayor valor de este trabajo no es un clasificador desplegable, que con los datos actuales no lo es, sino el marco metodológico reproducible y libre de fugas: el pipeline de extracción de características limpio, el protocolo de bootstrap multivariado sincronizado, el anclaje del label, la partición y validación a nivel de paciente y el esquema de evaluación clínica son independientes del dataset fuente. El salto de desempeño necesario para un uso clínico requiere la

cohorte de aproximadamente 20.000 partos del Hospital de Puerto Montt, sobre la que este marco es directamente aplicable, avanzando hacia el objetivo final del proyecto: un sistema “copiloto” que apoye al equipo obstétrico en la detección temprana de compromiso fetal intraparto.

9. REFERENCIAS BIBLIOGRÁFICAS

- Akaike, H. (1974). A new look at the statistical model identification. IEEE Transactions on Automatic Control, 19(6), 716-723. <https://doi.org/10.1109/TAC.1974.1100705>
- Alfirevic, Z., Gyte, G. M. L., Cuthbert, A., & Devane, D. (2017). Continuous cardiotocography (CTG) as a form of electronic fetal monitoring (EFM) for fetal assessment during labour. Cochrane Database of Systematic Reviews, (2), CD006066. <https://doi.org/10.1002/14651858.CD006066.pub3>
- Ayres-de-Campos, D., Spong, C. Y., & Chandrachud, E. (2015). FIGO consensus guidelines on intrapartum fetal monitoring: Cardiotocography. International Journal of Gynecology & Obstetrics, 131(1), 13-24. <https://doi.org/10.1016/j.ijgo.2015.06.020>
- Biblioteca del Congreso Nacional de Chile. (1999). Ley N° 19.628 sobre Protección de la Vida Privada.
- Biblioteca del Congreso Nacional de Chile. (2006). Ley N° 20.120 sobre la investigación científica en el ser humano, su genoma, y prohíbe la clonación humana.
- Biblioteca del Congreso Nacional de Chile. (2012). Ley N° 20.584 que regula los derechos y deberes que tienen las personas en relación con acciones vinculadas a su atención en salud.
- Cahill, A. G., Tuuli, M. G., Stout, M. J., López, J. D., & Macones, G. A. (2018). A prospective cohort study of fetal heart rate monitoring: deceleration area is predictive of fetal acidemia. American Journal of Obstetrics and Gynecology, 218(5), 523.e1-523.e12. <https://doi.org/10.1016/j.ajog.2018.01.026>
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of International Conference on Knowledge Discovery and Data Mining, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Chudáček, V., Spilka, J., Bursa, M., Janku, P., Hruban, L., Huptych, M., & Lhotská, L. (2014). Open access intrapartum CTG database. BMC Pregnancy and Childbirth, 14, 16. <https://doi.org/10.1186/1471-2393-14-16>
- DeLong, E. R., DeLong, D. M., & Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: a nonparametric approach. Biometrics, 44(3), 837-845. <https://doi.org/10.2307/2531595>
- Efron, B., & Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall/CRC. <https://doi.org/10.1201/9780429246593>
- Georgieva, A., Papageorgiou, A. T., Payne, S. J., Moulden, M., & Redman, C. W. G. (2014). Phase-rectified signal averaging for intrapartum electronic fetal heart rate monitoring is related to acidemia at birth. BJOG, 121(7), 889-894. <https://doi.org/10.1111/1471-0528.12568>

- Georgieva, A., Papageorgiou, A. T., Payne, S. J., Moulden, M., & Redman, C. W. G. (2017). Computerized data-driven interpretation of the intrapartum cardiotocogram: a cohort study. *Acta Obstetrica et Gynecologica Scandinavica*, *96*(7), 883-891. <https://doi.org/10.1111/aogs.13136>
- Henry, K. E., Hager, D. N., Pronovost, P. J., & Saria, S. (2015). A targeted real-time early warning score (TREWScore) for septic shock. *Science Translational Medicine*, *7*(299), 299ra122. <https://doi.org/10.1126/scitranslmed.aab3719>
- Kapaya, H., Jacques, R., Almond, T., Rosser, M. H., & Anumba, D. (2020). Is short-term-variation of fetal-heart-rate a better predictor of fetal acidemia in labour? A feasibility study. *PLoS ONE*, *15*(8), e0236982. <https://doi.org/10.1371/journal.pone.0236982>
- Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, *6*(4). <https://doi.org/10.1145/2382577.2382579>
- Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, *17*(3), 1217-1241. <https://doi.org/10.1214/aos/1176347265>
- Lawn, J. E., Cousens, S., & Zupan, J. (2005). 4 million neonatal deaths: When? Where? Why? *The Lancet*, *365*(9462), 891-900. [https://doi.org/10.1016/S0140-6736\(05\)71048-5](https://doi.org/10.1016/S0140-6736(05)71048-5)
- Pincus, S. M. (1991). Approximate entropy as a measure of system complexity. *Proceedings of the National Academy of Sciences*, *88*(6), 2297-2301. <https://doi.org/10.1073/pnas.88.6.2297>
- Politis, D. N., & Romano, J. P. (1994). The stationary bootstrap. *Journal of the American Statistical Association*, *89*(428), 1303-1313. <https://doi.org/10.1080/01621459.1994.10476870>
- Richman, J. S., & Moorman, J. R. (2000). Physiological time-series analysis using approximate entropy and sample entropy. *American Journal of Physiology-Heart and Circulatory Physiology*, *278*(6), H2039-H2049. <https://doi.org/10.1152/ajpheart.2000.278.6.H2039>
- Saeb, S., Lonini, L., Jayaraman, A., Mohr, D. C., & Kording, K. P. (2017). The need to approximate the use-case in clinical machine learning. *GigaScience*, *6*(5), gix019. <https://doi.org/10.1093/gigascience/gix019>
- Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, *10*(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Sarnat, H. B., & Sarnat, M. S. (1976). Neonatal encephalopathy following fetal distress: A clinical and electroencephalographic study. *Archives of Neurology*, *33*(10), 696-705. <https://doi.org/10.1001/archneur.1976.00500100030012>

- Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2), 461-464. <https://doi.org/10.1214/aos/1176344136>
- Spilka, J., Chudáek, V., Koucký, M., et al. (2012). Using nonlinear features for fetal heart rate classification. *Biomedical Signal Processing and Control*, 7(4), 350-357. <https://doi.org/10.1016/j.bspc.2011.06.008>
- Tarvonen, M., Hovi, P., Sainio, S., Vuorela, P., Andersson, S., & Teramo, K. (2021). Intrapartal cardiotocographic patterns and hypoxia-related perinatal outcomes in pregnancies complicated by gestational diabetes mellitus. *Acta Diabetologica*, 58(11), 1563-1573. <https://doi.org/10.1007/s00592-021-01756-0>
- World Medical Association. (2013). World Medical Association Declaration of Helsinki: Ethical principles for medical research involving human subjects. *JAMA*, 310(20), 2191-2194. <https://doi.org/10.1001/jama.2013.281053>