

Recurrencia en Cadenas de Markov utilizando Polinomios Ortogonales

Jaime Alonso, Elias Basulto, Nicolás Bustos.

July 22, 2026

Abstract

Este informe explora la aplicación de polinomios ortogonales en el estudio de Cadenas de Markov, con un enfoque particular en determinar la recurrencia de estados. Se presenta una revisión teórica de conceptos clave como cadenas de Markov, polinomios ortogonales, y la función de Stieltjes. Se desarrolla un teorema que establece la relación entre la recurrencia de un estado y las propiedades de la función de Stieltjes asociada a los polinomios ortogonales correspondientes. El informe incluye una demostración detallada de este teorema y concluye con un ejemplo numérico que ilustra el cálculo y visualización de la función de Stieltjes para una caminata aleatoria simple. Este trabajo demuestra cómo la teoría de polinomios ortogonales puede enriquecer el análisis de procesos estocásticos, proporcionando herramientas potentes para caracterizar el comportamiento a largo plazo de sistemas markovianos.

Palabras clave: polinomios ortogonales, cadenas de Markov, función de Stieltjes, recurrencia, procesos estocásticos.

1 Introducción

Los polinomios ortogonales, originados en las teorías de fracciones continuas y el problema de los momentos del siglo XIX, son una herramienta fundamental en diversos campos de la matemática y aplicaciones de la física. Los polinomios clásicos, como los de Legendre, Laguerre y Hermite, así como los discretos, debido a Chebyshev, Krawtchouk y otros, han encontrado un uso generalizado en todas las áreas de la ciencia y la ingeniería. Ofrecen una base teórica para la aproximación de funciones y la resolución de ecuaciones diferenciales.

En este informe, revisaremos la aplicación de los polinomios ortogonales en un área específica: las Cadenas de Markov. Integrar el uso de polinomios ortogonales enriquece el estudio de procesos markovianos y estocásticos, los cuales tienen aplicaciones significativas en la actualidad, tales como procesos de optimización en sistemas de colas, patrones de compra y reemplazo de equipos en empresas. Un problema clásico en éstos ámbitos es definir si un estado del modelo es recurrente o transitivo, recurrente positivo o recurrente nulo.

Mediante el uso de polinomios ortogonales, veremos una aplicación a este tipo de problemas.

2 Definiciones y Teorema

2.1 Conceptos, definiciones y teoremas previos

Todo cocinero antes de cocinar un platillo de lujo debe reunir los ingredientes previos que se utilizarán en el plato a cocinar. De manera similar, definiremos conceptos claves y propiedades que se utilizarán para el platillo principal de éste informe.

2.1.1 Cadenas de Markov [3]

En teoría de la probabilidad, se conoce como cadena de Márkov o modelo de Márkov a un proceso estocástico discreto, en el que la probabilidad de que ocurra un evento depende solamente del evento inmediatamente anterior. Dentro de estos modelos definiremos principalmente 8 aspectos.

1. Espacio de Estados: Para una cadena de Markov se define un espacio de estados (también llamados nodos), dado por la posición o etapa en el que el sistema puede estar. Este conjunto puede ser finito o infinito. Comúnmente se denomina por el conjunto $S = \{x_0, x_1, x_2, \dots\}$

Al inicio de un proceso, la etapa o posición inicial se denomina estado inicial y se denomina X_0 y dado un tiempo t el estado en el que se encuentra el sistema se denomina como X_t . Para una cadena de Markov discreta t toma valores discretos y el sistema evoluciona desde el estado X_t al estado X_{t+1} dado el cambio del valor t a $t + 1$ y una probabilidad de transición.

2. Probabilidad de Transición: Las cadenas de Markov se caracterizan por evolucionar de un estado a otro (o al mismo estado). Esta transición está dada por una probabilidad que está dada solo por el estado actual de un sistema y el estado siguiente. Esta propiedad se llama propiedad Markoviana y formalmente se describe de la siguiente forma: Dado un tiempo discreto $\{X_t : t = 0, 1, 2, \dots\}$ con espacio de estados discreto S , Entonces $\forall t \geq 0$ y para cualesquiera $x_0, x_1, \dots, x_{t+1} \in S$ se satisface

$$P[X_{t+1} = x_{t+1} | X_0 = x_0, X_1 = x_1, \dots, X_t = x_t] = P[X_{t+1} = x_{t+1} | X_t = x_t]$$

Esta probabilidad de Transición suele ser denominada arco, el cual puede ser unidireccional o bidireccional y se denomina generalmente como p_{ij}

Un aspecto clave es que la suma de las probabilidades de transición desde un estado debe ser 1, sin embargo la suma de las probabilidades de la transición hacia un estado no necesariamente debe ser 1.


3. Matriz de Transición: Dado el conjunto de estados $S = \{x_1, x_2, x_3, \dots, x_n\}$, se puede generar una matriz que contenga la información de la probabilidad de transición desde el estado i al estado j en el tiempo t , guardando en la entrada i, j de la matriz esta probabilidad.

Por ejemplo:

Consideremos la matriz de transición en una etapa:

$$P = \begin{pmatrix} 0.2 & 0.3 & 0.5 \\ 0.1 & 0 & 0.9 \\ 0.55 & 0 & 0.45 \end{pmatrix}$$

Podemos representar esto como un grafo:



4. Cadena Homogénea y Heterogénea: Se dice que una cadena es Homogénea si la probabilidad de ir un estado a otro no depende del tiempo del sistema, es decir:

$$P[X_{t+1} = j | X_t = i] = P[X_1 = j | X_0 = i] \quad \forall t \geq 0, i, j \in S$$

Por otra parte, se dice que una cadena de Markov es Heterogénea si no es Homogénea.

Notar que para el caso de cadena Homogénea, la matriz de transición es independiente del tiempo del sistema.

5. Probabilidad de primera visita: Dado un estado inicial $X_0 = x_i$, se denomina probabilidad de primera visita para el nodo x_j en un tiempo n a la probabilidad de que $X_n = x_j$. Se representa como $f_{ij}(n)$ y formalmente se define como

$$f_{ij}(n) = P[X_n = j, X_{n-1} \neq j, X_{n-2} \neq j, \dots, X_1 \neq j | X_0 = i]$$

Cuando $i = j$ la probabilidad de primera visita $f_{ii}(n)$ se llama probabilidad de primer retorno

6. Probabilidad de eventual visita: La probabilidad de que un sistema tome eventualmente un estado j habiendo iniciado desde un estado i se denomina f_{ij} y está dado por:

$$f_{ij} = \sum_{n=1}^{\infty} f_{ij}(n)$$

7. Estados Recurrentes y Transcientes: Un estado i se dice recurrente si $f_{ii} = 1$ y se dice transciente si $f_{ii} < 1$
8. Tiempo medio de recurrencia: Se le dice tiempo medio de recurrencia entre el estado i y el j a la esperanza del mínimo $n > 0$ tal que $X_n = j | X_0 = i$, es decir:

$$\mu_{ij} = \sum_{n=1}^{\infty} n \cdot f_{ij}(n)$$

Donde μ_{ij} es el tiempo medio de recurrencia entre i y j . Además, cuando $i = j$ se suele denotar el tiempo medio de recurrencia como μ_i

Se dice que un estado recurrente es recurrente nulo si $\mu_i = \infty$ y se dice que es recurrente positivo si $\mu_i < \infty$

2.1.2 La integral de Lebesgue–Stieltjes [7]

$$\int_a^b f(x) dg(x)$$

sea $f : [a, b] \rightarrow \mathbb{R}$ Borel-medible y acotada y $g : [a, b] \rightarrow \mathbb{R}$ de variación acotada en $[a, b]$ y es continua por la derecha, o cuando f es no negativa y g es monótona y continua por la derecha.

$$\mu_g(E) = \inf \left\{ \sum_i \mu_g(I_i) : E \subseteq \bigcup_i I_i \right\}$$

el ínfimo está tomado sobre todos los cubrimientos de E por intervalos semiabiertos.

Entonces la integral de Lebesgue en vez de tomar la indicatriz por la medida del conjunto se va a tomar la indicatriz por la medida de la imagen del conjunto en g .

2.1.3 Función Peso Continua [1]

Un peso continuo es una función no negativa tal que $w(x)dx$ en un dominio $\omega \subset \mathbb{R}^n$, si hablamos de $n=1$ podemos decir que ω puede ser un intervalo $[a, b]$. dx es Lebesgue medible y $w : \Omega \rightarrow \mathbb{R}^+$

Definición formal: Si $f : \Omega \rightarrow \mathbb{R}$ es una función evaluada en los reales, entonces la integral sin peso sería

$$\int_{\Omega} f(x) dx$$

y la integral con peso es

$$\int_{\Omega} f(x)w(x) dx$$

Notar que solo necesitamos que la integral esté en $\mathcal{L}^1$ con respecto al peso para que esta integral sea finita

2.1.4 Distribución degenerada [9]

Una distribución degenerada invariante puede considerarse como el caso límite de una distribución continua cuya varianza tiende a cero, provocando que la densidad de probabilidad se convierta en una función delta en k_0 , donde todo el peso se concentra en k_0 . La función de distribución acumulada de la distribución degenerada invariante es:

$$F_{k_0}(x) = \begin{cases} 1, & \text{si } x \geq k_0 \\ 0, & \text{si } x < k_0 \end{cases}$$

2.1.5 Sequilinealidad [10]

Una σ -forma-sequilineal es una forma de extender las formas bilineales. Específicamente involucran un anti-automorfismo en uno de sus argumentos. Matemáticamente: sea M una aplicación aditiva $\phi : M \times M \rightarrow K$ con un anti-automorfismo asociado σ de un anillo de división K tal que, para todos x, y en M y para todos α, β en K ,

$$\phi(x\alpha, y\beta) = \sigma(\alpha)\phi(x, y)\beta.$$

El anti-automorfismo asociado a σ para cualquier forma sesquilineal no nula ϕ está determinado por ϕ .

2.1.6 Problema Momento de Hamburger [8]

Dada una secuencia $(m_0, m_1, m_2, \dots)$, donde existe una medida poostiva borel positive μ (por instancia, la medida dedterminada por la distribucion acumulada funcion de una variable aleatoria) en la linea real tal que

$$m_n = \int_{-\infty}^{\infty} x^n d\mu(x)$$

El problema del momentos de hamburguer es resoluble (eso es, (m_n) es una secuencia de momentos) si y solo si el correspondiente kernel en los enteros no negativos

$$A = \begin{pmatrix} m_0 & m_1 & m_2 & \cdots \\ m_1 & m_2 & m_3 & \cdots \\ m_2 & m_3 & m_4 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

Es definida positiva, i.e.

$$\sum_{j,k \geq 0} m_{j+k} c_j \overline{c_k} \geq 0$$

para una secuencia $(c_j)_{j \geq 0}$ de numeros complejos finitos (i.e. $c_j = 0$ excepto para unos valores finitos de unos j).

2.1.7 Convergencia en una medida de probabilidad [6]

Una sucesión ν_n de medidas de probabilidad deterministas en un espacio Ω con σ -álgebra asociada $\mathcal{F}$ se dice que converge débilmente a una medida de probabilidad ν si para toda función acotada y continua f

$$\int_{\Omega} f d\nu_n \rightarrow \int_{\Omega} f d\nu$$

cuando $n \rightarrow \infty$. Si ν_n es en sí misma aleatoria, nos interesa en cambio la convergencia débil a ν ya sea en probabilidad o casi seguramente.

2.1.8 Teorema: Metodo de los momentos [8]

Suponemos que (μ_n) y μ son probabilidades en $\mathbb{R}$ con momentos de todo orden y tal que μ es det(H). Si

$$\lim_{n \rightarrow \infty} \int x^k d\mu_n(x) = \int x^k d\mu(x) \quad \text{for } k = 0, 1, \dots$$

Entonces $\mu_n \rightarrow \mu$ debil.

2.1.9 Teorema de Markov Stieljevs [4]

Para enunciar el teorema, se usarán los siguientes conjuntos

Para cada $n \geq 1$, sea Λ_n el conjunto de ceros de P_n , y consideremos la probabilidad discreta τ_n con masa

$$m_{\lambda} = \left(\sum_{i=0}^{n-1} P_i(\lambda)^2 \right)^{-1}$$

en $\lambda \in \Lambda_n$.

Se tiene que

$$\frac{Q_n(z)}{P_n(z)} = \int \frac{d\tau_n(x)}{z - x} \quad \text{para } z \in \mathbb{C} \setminus \Lambda_n$$

Definimos

$$\Lambda = \bigcap_{N=1}^{\infty} M_N, \quad \text{donde} \quad M_N = \bigcup_{n=N}^{\infty} \Lambda_n,$$

obtenemos un subconjunto cerrado de $\mathbb{R}$, y cualquier solución natural μ del problema de momentos, tiene $\text{supp}(\mu) \subseteq \Lambda$. Además, si para cualquier solución μ del problema de momentos definimos $a_{\mu} = \inf \text{supp}(\mu)$, $b_{\mu} = \sup \text{supp}(\mu)$, entonces $\Lambda \subseteq M_N \subseteq [a_{\mu}, b_{\mu}]$. Donde supp es el soporte, es decir, el conjunto de puntos donde la función no es cero.

Teorema de Markov Stieljevs [4]

Sea μ igual a $\det(H)$ donde μ es una medida (positiva) en el conjunto Λ . Aquí y en lo que sigue, P_n son los polinomios ortonormales asociados con μ , y Q_n son los polinomios correspondientes del segundo tipo. entonces

$$\lim_{n \rightarrow \infty} \frac{Q_n(z)}{P_n(z)} = \int \frac{d\mu(x)}{z-x} \quad \text{para } z \in \mathbb{C} \setminus \Lambda,$$

Proof. Por lo anterior el k -ésimo momento de τ_n converge para $n \rightarrow \infty$ al k -ésimo momento de μ para cualquier k (son en realidad igual en n suficiente grande). por el metodo de momentos $\tau_n \rightarrow \mu$ debil en $\mathbb{R}$ y con mayor razon en el subconjunto cerrado M_N para cualquier $N \in \mathbb{N}$, porque contiene $\text{supp}(\mu)$ y $\text{supp}(\tau_n)$ para $n \geq N$. en partucual sigue que

$$\lim_{n \rightarrow \infty} \int \frac{d\tau_n(x)}{z-x} = \int \frac{d\mu(x)}{z-x} \quad \text{para cualquier } z \in \mathbb{C} \setminus \Lambda.$$

[7]

Para ver que la convergencia es uniforme para $z \in K$, donde $K \subseteq \mathbb{C} \setminus \Lambda$ es un compacto, notamos que $K \cap M_N = \emptyset$ para N suficientemente grande, y despues existe un $C > 0$ tal que $|z-x| \geq C$ para $z \in K$, $x \in M_N$.

Para un $\varepsilon > 0$ existe una $z_1, \dots, z_p \in K$ tal que las bolas $D(z_i, \varepsilon)$ cubren K . para un $z \in K$ elegimos $i \in \{1, \dots, p\}$ tal que $|z - z_i| < \varepsilon$, por lo tanto por $x \in M_N$

$$\left| \frac{1}{z-x} - \frac{1}{z_i-x} \right| \leq \frac{\varepsilon}{C^2}.$$

para $n \geq N$ entonces obtenemos finalmente

$$\left| \int \frac{d\mu(x)}{z-x} - \int \frac{d\tau_n(x)}{z-x} \right| \leq \frac{2\varepsilon}{C^2} + \left| \int \frac{d\mu(x)}{z_i-x} - \int \frac{d\tau_n(x)}{z_i-x} \right|,$$

de donde la convergencia uniforme se tiene esto. $\square$

2.1.10 Producto interno y norma [1]

1. Para la construccion de polinomios ortogonales es importante definir el producto interno entre funciones. Supongamos que α es cierta una función no decreciente en (a, b) ($\alpha(x) \neq \text{const}$) tal que si el intervalo (a, b) es no acotado, o sea si $a = -\infty$, entonces $\lim_{x \rightarrow -\infty} \alpha(x) > -\infty$ y si $b = \infty$, entonces $\lim_{x \rightarrow \infty} \alpha(x) < \infty$. Diremos que una función f pertenece al espacio $L_\alpha^p[a, b]$ si

$$\int_a^b |f(x)|^p d\alpha(x) < \infty.$$

(1)

Nos interesará el caso $p = 2$, i.e, $f \in L_\alpha^2[a, b]$. Definiremos el producto interno de dos funciones f y g pertenecientes a $L_\alpha^2[a, b]$ como la integral de Stieltjes-Lebesgue

$$\langle f, g \rangle = \int_a^b f(x)g(x)d\alpha(x).$$

(2)

Para una función α prefijada de antemano, la ortogonalidad respecto a la distribución $d\alpha$ vendrá definida por la relación $\langle f, g \rangle = 0$, y diremos que f y g son ortogonales, o que, f es ortogonal a g respecto a la distribución $d\alpha$. Si α es absolutamente continua en el intervalo (a, b) , el producto escalar (1) se puede reescribir como la integral:

$$\langle f, g \rangle = \int_a^b f(x)g(x)\rho(x)dx,$$

donde ρ es una función medible no negativa, es decir:

$$0 < \int_a^b \rho(x)dx < \infty.$$

A la función ρ se le denomina función peso.

2.1.11 Norma, Norma nula y Normalización

Consideremos ahora el espacio vectorial $L^2_\alpha(a, b)$. Definamos en este espacio el producto interno dado por $\langle f, g \rangle$. La norma entonces está dada por la expresión

$$\|f\| = \sqrt{\langle f, f \rangle}.$$

Si $\|f\| = 0$ y f es continua *ctp*, entonces f es nula *ctp*. Si $\|f\| = 1$ diremos que f está normalizado. Si f no es nula, entonces para cierto valor $\lambda \neq 0$ el vector λf está normalizado. Se le llama normalización a la función $u(f) = \lambda \cdot f$ donde $\lambda = \frac{1}{\|f\|}$.

2.1.12 Polinomios Ortogonales [2]

Sea $(P_n)_n$ una sucesión de polinomios, diremos que $(P_n)_n$ es una sucesión de polinomios ortogonales con respecto a la medida $d\mu(x)$ si se cumple que:

- (a) $d_n^2 := \langle P_n, P_n \rangle > 0, \forall n = 0, 1, 2, \dots$
- (b) P_n es un polinomio de grado n
- (c) $\langle P_n, P_m \rangle = 0, m \neq n, \forall (n, m) = 0, 1, 2, \dots$

Si una sucesión de polinomios es Ortogonal, la denominaremos como SPO

2.1.13 Ortonormalidad

Una sucesion sera Ortonormal si es Ortogonal y si $\forall n \langle P_n, P_n \rangle = 1$

2.2 Teoremas Ortogonalidad y Cadenas de Markov

2.2.1 Recurrencia a 3 términos [2]

Teorema: Sea $(P_n)_n$ una SPO con respecto a cierta medida $d\mu(x)$. Entonces, la SPO $(P_n)_n$ satisface una relación de recurrencia a tres términos de la forma:

$$xP_n(x) = \alpha_n P_{n+1}(x) + \beta_n P_n(x) + \gamma_n P_{n-1}(x), \quad n = 0, 1, 2, \dots \quad (1)$$

Generalmente se suele imponer que $P_{-1}(x) = 0$ y $P_0(x) = 1$, con lo que una SPO queda determinada de forma única conocidas las sucesiones $(\alpha_n)_n$, $(\beta_n)_n$ y $(\gamma_n)_n$.

En el caso particular donde los polinomios son ortonormales la RRTT (3) se transforma en

$$xp_n(x) = a_n p_{n+1}(x) + b_n p_n(x) + a_{n-1} p_{n-1}(x), \quad a_n > 0, \quad n \geq 0,$$

donde $b_n = \beta_n$ y $a_n = \sqrt{\alpha_{n+1}\gamma_n}$. El recíproco también es cierto y se llama Teorema de Favard.

2.2.2 Teorema Ortogonalidad [2]

Supongamos que una sucesión de polinomios mónicos $(P_n)_n$ satisface una relación de recurrencia a tres términos de la forma:

$$xP_n(x) = P_{n+1}(x) + \beta_n P_n(x) + \gamma_n P_{n-1}(x), \quad n \geq 0, \quad (2)$$

con $\gamma_n > 0$ y $\beta_k \in \mathbb{R}$ ($k = 0, 1, 2, \dots$), y las condiciones iniciales $P_{-1}(x) = 0$ y $P_0(x) = 1$.

Entonces, dichos polinomios P_n son ortonormales en $L^2(\mu)$, siendo $d\mu(x)$ cierta medida positiva sobre la recta real.

Nótese que la RRTT (3) se puede escribir en forma matricial

$$x\mathbf{P}_n(x) = \mathbf{J}_{n+1}\mathbf{P}_n(x) + \alpha_n P_{n+1}(x)\mathbf{e}_n,$$

donde $\mathbf{P}_n(x) = [P_0(x), \dots, P_n(x)]^T$, $\mathbf{e}_n = [0, 0, \dots, 0, 1]^T \in \mathbb{R}^{n+1}$ y $\mathbf{J}_{n+1}$ es la matriz tridiagonal de orden $n+1$

$$\mathbf{J}_{n+1} = \begin{bmatrix} \beta_0 & \alpha_0 & 0 & 0 & \dots & 0 & 0 \\ \gamma_1 & \beta_1 & \alpha_1 & 0 & \dots & 0 & 0 \\ 0 & \gamma_2 & \beta_2 & \alpha_2 & \dots & 0 & 0 \\ 0 & 0 & \gamma_3 & \beta_3 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \dots & \beta_{n-1} & \alpha_{n-1} \\ 0 & 0 & 0 & 0 & \dots & \gamma_n & \beta_n \end{bmatrix}.$$

Una de las consecuencias de lo anterior es que si denotamos por $\{x_{nj}\}_{1 \leq j \leq n}$ a los ceros del polinomio P_n , entonces se sigue que cada x_{nj} es un autovalor de la matriz tridiagonal $\mathbf{J}_n$ y que $\mathbf{P}_{n-1}(x_{nj}) := [P_0(x_{nj}), \dots, P_{n-1}(x_{nj})]^T$ es el correspondiente autovector.

Si tomamos $\alpha_n = 1$ y $\gamma_n > 0$ para todo $n = 1, 2, \dots$ la sucesión de polinomios mónicos $(P_n)_{n \geq 0}$ definida por la RRTT aparece como los denominadores de los aproximantes de Padé de la fracción continua

$$\cfrac{1}{x - \beta_0 - \cfrac{\gamma_1}{x - \beta_1 - \cfrac{\gamma_2}{x - \beta_2 - \cfrac{\gamma_3}{x - \beta_3 - \ddots}}}}$$

Por otro lado, los numeradores de los aproximantes de Padé, que denotaremos por $(P_n^{(1)})_{n \geq 0}$, satisfacen una RRTT similar (desplazada en el índice n)

$$xP_n^{(1)}(x) = P_{n+1}^{(1)}(x) + \beta_{n+1}P_n^{(1)}(x) + \gamma_{n+1}P_{n-1}^{(1)}(x), \quad n \geq 0,$$

con las condiciones iniciales $P_{-1}^{(1)} = 0$ y $P_0^{(1)} = 1$. La fracción continua anterior converge a cierta función $F(z; \sigma)$ que es analítica en $\mathbb{C} \setminus \text{supp}(d\mu(x))$, i.e., se tiene el Teorema de Markov-Stieltjes

$$-\lim_{n \rightarrow +\infty} \frac{\mu_0 P_{n-1}^{(1)}(z)}{P_n(z)} = F(z; \mu) := \int_{-\infty}^{+\infty} \frac{d\mu(x)}{x - z}, \quad z \in \mathbb{C} \setminus \text{supp}(d\mu(x)),$$

donde $\mu_0 = \int_{-\infty}^{+\infty} d\mu(x)$ es el primer momento de la medida $d\mu(x)$ y F es la función de Stieltjes asociada a la medida $d\mu(x)$. De hecho, la medida $d\mu(x)$ se puede recuperar a partir de la función de Stieltjes por la fórmula de inversión de Stieltjes:

$$\mu(x) - \mu(y) = \lim_{\epsilon \rightarrow 0^+} \frac{1}{\pi} \int_y^x \Im F(t + i\epsilon, \mu) dt,$$

que en caso de que la medida sea absolutamente continua $d\mu(x) = \omega(x)dx$ se transforma en

$$\omega(x) = \lim_{\epsilon \rightarrow 0^+} \frac{1}{\pi} \Im F(x + i\epsilon, \mu),$$

y si hay un punto de masa entonces

$$\mu(\{x\}) = \lim_{\epsilon \rightarrow 0^+} \frac{1}{\pi} \epsilon \Im F(x + i\epsilon, \mu) > 0.$$

Aquí se asume que $d\mu(x)$ está normalizada de forma que

$$\mu(-\infty) = 0, \quad \mu(x) = \frac{\mu(x+0) + \mu(x-0)}{2}$$

e $\Im z$ denota la parte imaginaria de z . Nótese que tomando $n \rightarrow \infty$ (con la métrica adecuada) tenemos, para la SPO la ecuación matricial

$$xP(x) = JP, \quad J = \begin{bmatrix} \beta_0 & \alpha_0 & 0 & 0 & \dots & 0 & 0 & \dots \\ \gamma_1 & \beta_1 & \alpha_1 & 0 & \dots & 0 & 0 & \dots \\ 0 & \gamma_2 & \beta_2 & \alpha_2 & \dots & 0 & 0 & \dots \\ 0 & 0 & \gamma_3 & \beta_3 & \dots & 0 & 0 & \dots \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \dots \\ 0 & 0 & 0 & 0 & \dots & \beta_{n-1} & \alpha_{n-1} & \dots \\ 0 & 0 & 0 & 0 & \dots & \gamma_n & \beta_n & \dots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \ddots \end{bmatrix},$$

donde $P(x) = [P_0(x), \dots, P_n(x), \dots]^T$ y J es cierta matriz asociada con el operador de Jacobi. De hecho, si trabajamos con sucesiones de polinomios ortonormales lo anterior se convierte en

$$x \begin{bmatrix} p_0(x) \\ p_1(x) \\ p_2(x) \\ p_3(x) \\ \vdots \end{bmatrix} = \begin{bmatrix} b_0 & a_0 & 0 & 0 & \dots \\ a_0 & b_1 & a_1 & 0 & \dots \\ 0 & a_1 & b_2 & a_2 & \dots \\ 0 & 0 & a_2 & b_3 & \dots \\ \vdots & \vdots & \vdots & \vdots & \ddots \end{bmatrix} \begin{bmatrix} p_0(x) \\ p_1(x) \\ p_2(x) \\ p_3(x) \\ \vdots \end{bmatrix} \Leftrightarrow xp(x) = Jp(x)$$

donde $p(x) = [p_0(x), \dots, p_n(x), \dots]^T$, y J es la matriz tridiagonal, real y simétrica (comúnmente denominada matriz de Jacobi)


$$J = \begin{bmatrix} b_0 & a_0 & 0 & 0 & \dots \\ a_0 & b_1 & a_1 & 0 & \dots \\ 0 & a_1 & b_2 & a_2 & \dots \\ 0 & 0 & a_2 & b_3 & \dots \\ \vdots & \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

2.2.3 Teorema Cadena de Markov y recurrencia [2]

Lema 1. $a \in \mathbb{R}$ tiene inverso ssi $a \neq 0$.

Teorema 1. Sea una caminata aleatoria con matriz de transición tridiagonal y sea $F(z; \mu_i)$ la función de Stieltjes asociada a la correspondiente familia de polinomios ortonormales $(p_n)_n$. Entonces el estado i de dicha caminata es recurrente si $F(1; \mu_1) = -\infty$ y positivamente recurrente si $\mu_i(\{1\}) > 0$, siendo la medida $d\mu_i(x) = p_i(x)^2 d\mu(x)$ la medida espectral asociada a la familia $(p_n)_n$ y $d\mu(x)$ la medida de ortogonalidad de $(p_n)_n$.

Proof. Vamos a considerar la siguiente cadena de markov, como una caminata aleatoria:



Con la siguiente matriz de transición:

$$P = \begin{bmatrix} r_0 & p_0 & 0 & 0 & 0 & \cdots \\ q_1 & r_1 & p_1 & 0 & 0 & \cdots \\ 0 & q_2 & r_2 & p_2 & 0 & \cdots \\ 0 & 0 & q_3 & r_3 & p_3 & \cdots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots \end{bmatrix}, r_0 + p_0 = 1, \quad p_i + q_i + r_i = 1, \quad \forall i \geq 1,$$

Donde claramente la probabilidad de ir de un estado al anterior o al siguiente son distintas de cero. En base a esto podemos definir la matriz:

$$\Pi = \begin{bmatrix} \pi_0 & 0 & 0 & 0 & 0 & \cdots \\ 0 & \pi_1 & 0 & 0 & 0 & \cdots \\ 0 & 0 & \pi_2 & 0 & 0 & \cdots \\ 0 & 0 & 0 & \pi_3 & 0 & \cdots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots \end{bmatrix}, \frac{\pi_i}{\pi_{i-1}} = \sqrt{\frac{p_{i-1}}{q_i}}, \quad i \geq 1,$$

Seguido de:

$$\Pi \cdot P \cdot \Pi^{-1} = \begin{bmatrix} r_0 & a_0 & 0 & 0 & 0 & \cdots \\ a_0 & r_1 & a_1 & 0 & 0 & \cdots \\ 0 & a_1 & r_2 & a_2 & 0 & \cdots \\ 0 & 0 & a_2 & r_3 & a_3 & \cdots \\ \vdots & \vdots & \vdots & \vdots & \vdots & \ddots \end{bmatrix} = \mathcal{J},$$

Con:

$$a_i = \sqrt{p_i q_{i+1}} > 0, \quad i \geq 0$$

Donde J es la matriz de Jacobi correspondiente a la sucesión de polinomios ortonormales $(p_n)_n$. Dado (ecuación xp) y por inducción se puede ver que:

$$x^n p(x) = J^n p(x)$$

Donde cada elemento de la matriz J se calcula utilizando la fórmula de Karling-Mcgregor:

$$J_{ij}^n = \int_{\text{supp } d\mu} x^n p_i(x) p_j(x) d\mu(x), \quad i, j \geq 0$$

Donde término a término se usa la fórmula (2):

$$x^n p_i(x) = \sum_{j=i-n}^{i+n} J_{ij}^n p_j(x) \quad (3)$$

Donde $p_j(x) = 0$ si n es mayor a i . Ahora, viendo que todos los elementos de la matriz P se encuentran entre 0 y 1, estrictamente, por lo que se puede definir un operador $\hat{p}$ que va desde ℓ^1 a ℓ^1 , tal que $\hat{p} \cdot x = x \cdot P$, este operador es acotado por la norma del vector x , y por ende, continuo.

Dado que es acotado por $\|x\|$, $\|\hat{p}\| \leq 1$. Sabemos que espectro $\sigma(\hat{p}) \in \{z \in \mathbb{C} : |z| \leq \|\hat{p}\|\}$.

Usando el teorema de Favard, nos aseguramos que la familia de polinomios ortogonales asociadas a la matriz jacobiana, y por lo tanto a la matriz de transición sea ortogonal a alguna medida $d\mu(x)$ en la recta de los números reales. Sumando esto a lo anterior, obtenemos que el soporte de $d\mu(x)$ ($\text{supp}(d\mu(x))$) se encuentra entre -1 y 1.

Sea $f(x)$ una función analítica en el soporte $\text{supp } \mu(x)$ de la medida $d\mu(x)$

$$f(x) = \sum_{k \geq 0} c_k x^k.$$

Entonces

$$\begin{aligned} \int_{\text{supp } d\mu} f(x) p_i(x) p_j(x) d\mu(x) &= \int_{\text{supp } d\mu} \sum_{k \geq 0} c_k x^k p_i(x) p_j(x) d\mu(x) \\ &= \sum_{k \geq 0} c_k \int_{\text{supp } d\mu} x^k p_i(x) p_j(x) d\mu(x) \\ &= \sum_{k \geq 0} c_k J_{ij}^k \\ &= (f(J))_{ij}. \end{aligned}$$

Vamos a suponer que el soporte de $d\mu(x)$ es acotado (recordemos que en nuestro caso $\text{supp}(d\mu(x)) \in [-1, 1]$) y que z es lo suficientemente pequeño. Entonces

$$f(x) = \frac{1}{1 - zx}, \quad z \in \mathbb{C} \setminus \text{supp}(d\mu(x)),$$

es analítica en $\text{supp}(d\mu(x))$ por lo que aplicando la fórmula anterior obtenemos

$$\int_{\text{supp } d\mu} \frac{p_i(x)p_j(x)}{1 - zx} d\mu(x) = (I - zJ)_{ij}^{-1}.$$

Consideremos el caso especial $i = j$. En este caso

$$(I - zJ)_{ii}^{-1} = \int_{\text{supp } d\mu} \frac{p_i^2(x)d\mu(x)}{1 - zx} = \int_{\text{supp } d\mu} \frac{d\mu_i(x)}{1 - zx}, \quad d\mu_i(x) = p_i^2(x)d\mu(x),$$

donde $d\mu_i(x)$ se denomina medida espectral de la sucesión $(p_n)_n$. Desarrollando en serie la función $(1 - zx)^{-1}$ obtenemos

$$\begin{aligned} \int_{\text{supp } d\mu} \frac{d\mu_i(x)}{1 - zx} &= \int_{\text{supp } d\mu} \sum_{n \geq 0} (zx)^n d\mu_i(x) \\ &= \sum_{n \geq 0} \mu_n^{(i)} z^n = \hat{\mu}_i(z), \end{aligned}$$

donde $\mu_n^{(i)}$ son los momentos de orden n de la medida espectral $d\mu_i(x)$ y $\hat{\mu}_i(z)$ es la función generatriz de los correspondientes momentos. Luego la función $g(z) = (I - zJ)_{ii}^{-1}$ es la función generatriz de los momentos $\hat{\mu}_i(z)$ de la medida espectral de $(p_n)_n$ y en el caso especial $i = 0$, el de la medida original $d\mu(x)$.

Viendo la función generatriz de los retornos

$$p_i(z) = \sum_{n \geq 0} p_{ii}^{(n)} z^n = \sum_{n \geq 0} P_{ii}^n z^n = \sum_{n \geq 0} (\Pi \cdot J^n \cdot \Pi^{-1})_{ii} z^n$$

Luego:

$$p_i(z) = \sum_{n \geq 0} (\Pi \cdot J^n \cdot \Pi^{-1})_{ii} z^n = \sum_{n \geq 0} \pi_i J_{ii}^n \pi_i^{-1} z^n = \sum_{n \geq 0} J_{ii}^n z^n = (I - zJ)_{ii}^{-1}$$

Usando Karlin-Mcgregor nuevamente, con $J_{ii}^n = \mu_n^{(i)}$, donde $\mu_n^{(i)}$ son los momentos de orden n de la media espectral de los polinomios asociados a J . Usando que el soporte es $[-1, 1]$:

$$p_i(z) = \sum_{n \geq 0} \mu_n^{(i)} z^n = \int_{-1}^1 \frac{d\mu_i(x)}{1-xz} = s_i(z)$$

Dado que $p_i(1) = s_i(1)$ y la ecuación de renuevo:

$$p(z)q(z) = p(z) - 1 \iff q(z) = 1 - \frac{1}{p(z)}.$$

La probabilidad de los primeros retornos es $q(1) = 1 - \frac{1}{p(1)}$. Por lo tanto, el proceso será recurrente si se cumple que $s_i(1) = \infty$. Para afirmar recurrencia positiva tenemos que analizar el tiempo esperado de retorno, el cual se ve:

$$\tau_{ii} = \sum_{n \geq 1} nq_n = q_1 + 2q_2 + \dots + nq_n + \dots = \lim_{z \rightarrow 1^-} \frac{q(z) - q(1)}{z - 1} = \lim_{z \rightarrow 1^-} \frac{q(z) - 1}{z - 1} = q'(1^-)$$

Aplicando esto obtenemos que:

$$\tau_{ii} = \lim_{z \rightarrow 1^-} \frac{q(z) - 1}{z - 1} = \lim_{z \rightarrow 1^-} \frac{1}{(1-z)s_i(z)} = \lim_{z \rightarrow 1^-} \frac{1}{(1-z)p_i(z)} \quad (4)$$

Si τ_{ii} tiene un valor finito, entonces será positivamente recurrente, que esto sucede está fuertemente relacionado con la medida espectral de P , sobre si tiene un punto de masa en $x = 1$.

Para analizar esta relación hay que enfatizar que $s_i(z)$ está fuertemente relacionada con la función de Stieltjes $F(z; \mu)$ de la matriz J . En particular se tiene que:

$$s_i(z) = -z^{-1}F(z^{-1}; \mu_i), \quad s_0(z) := -s(z) = z^{-1}F(z^{-1}; \mu).$$

Para todo $z \neq 0$. Nos podemos fijar en que la medida espectral ($d\mu_i(x) = p_i^2(x)d\mu(x)$) tienen efectivamente un punto de masa en $x = 1$, si y sólo si $d\mu(x)$ también lo tiene. En vista de lo anterior, nos interesa analizar el caso cuando z tiende a 1 ($z \rightarrow 1$), para esto vamos a observar como se puede rescatar el punto de masa de $d\mu(z = 1)$ a partir de la función de Stieltjes. Procedemos a descomponer la medida de la siguiente forma:

$$d\mu(x) = \mu(1)\delta(x-1)dx + d\tilde{\mu}(x)$$

Estableciendo $\tilde{\mu}(x)$ como la medida sin un punto de masa en $x = 1$, si es que existe. Por lo tanto:

$$F(\zeta; \mu) = \frac{\mu(\{1\})}{\zeta - 1} + \int_{-1}^1 \frac{d\tilde{\mu}(x)}{x - \zeta}, \quad \zeta \in \mathbb{C} \setminus [-1, 1].$$

Seguido de:

$$(\zeta - 1)F(\zeta; \mu) = \mu(\{1\}) + \int_{-1}^1 \frac{\zeta - 1}{\zeta - x} d\tilde{\mu}(x).$$

Dado que $|\frac{\zeta-1}{\zeta-x}| < 1$ para todo $\zeta \in (1, \infty)$ por lo tanto, utilizando el teorema de la convergencia dominada (5) tenemos que:

$$\lim_{\zeta \rightarrow 1^+} \int_{-1}^1 \frac{\zeta-1}{\zeta-x} d\tilde{\mu}(x) = \int_{-1}^1 \lim_{\zeta \rightarrow 1^+} \frac{\zeta-1}{\zeta-x} d\tilde{\mu}(x) = \int_{-1}^1 0 d\tilde{\mu}(x) = 0$$

Esto sabiendo que $\zeta \in \mathbb{C} \setminus [-1, 1]$ y $x \in [-1, 1]$. Por lo cual:

$$\lim_{\zeta \rightarrow 1^+} (\zeta-1)F(\zeta; \mu) = \mu(\{1\}). \quad (5)$$

Usando la ecuación (4) y (5) y que $s(z) = -z^{-1}F(z^{-1}; \mu)$, tenemos que:

$$\tau_{ii} = \lim_{z \rightarrow 1^-} \frac{1}{(1-z)s_i(z)} = \frac{1}{\mu(\{1\})}.$$

Ahora, si la medida de ortogonalidad de los polinomios ortogonales normales presentes tiene masa distinta de cero en $x = 1$, dicho proceso será positivamente recurrente. $\square$

3 Resultados numéricos, ejemplo propio: Función de Stieltjes para una Caminata Aleatoria

En esta sección, presentamos el cálculo y la visualización de la función de Stieltjes asociada a una caminata aleatoria en una línea con reflejos en los extremos. Este análisis fue realizado por nosotros y se basa en la teoría de cadenas de Markov y polinomios ortogonales desarrollado en la sección anterior.

→ ¿Cómo se puede calcular y visualizar la función de Stieltjes para un proceso estocástico definido por una matriz de transición P y un estado inicial específico? ¿Cómo interpretarlo en el sentido de recurrencia?

Una caminata aleatoria en una línea con reflejos en los extremos se modela mediante una matriz de transición P de la siguiente forma:

$$P = \begin{pmatrix} 0.5 & 0.5 & 0 & 0 & 0 \\ 0.5 & 0 & 0.5 & 0 & 0 \\ 0 & 0.5 & 0 & 0.5 & 0 \\ 0 & 0 & 0.5 & 0 & 0.5 \\ 0 & 0 & 0 & 0.5 & 0.5 \end{pmatrix}$$

La función de Stieltjes $F(z; \mu_i)$ para el estado i se calcula resolviendo $(I - zP)^{-1}$, donde I es la matriz identidad.

Para visualizar la función de Stieltjes para el estado 0, se calcula $F(z; \mu_0)$ para valores de z en el intervalo $[0, 1]$, con un pequeño componente imaginario.




Figure 1: Función de Stieltjes para el Estado 0

El gráfico muestra la parte real (azul sólido) y la parte imaginaria (rojo punteado) de $F(z; \mu_0)$ en función de z .

La función de Stieltjes proporciona información crucial sobre la recurrencia y la positiva recurrencia de un estado en la cadena de Markov, lo cual es fundamental para entender sus propiedades espectrales. En este contexto, la función de Stieltjes $F(z; \mu_0)$ evaluada en z proporciona información sobre la probabilidad de recurrencia del estado inicial μ_0 y su comportamiento bajo transiciones de la cadena de Markov.

La presencia de picos o cambios abruptos en $F(z; \mu_0)$ indica la presencia de autovalores cercanos a la unidad, sugiriendo recurrencia del estado μ_0 . Al estudiar el gráfico generado, podemos inferir si el estado inicial μ_0 es recurrente positivo (si $F(z; \mu_0)$ tiene una singularidad en $z = 1$), recurrente nulo (si $F(z; \mu_0)$ no tiene singularidades cerca de $z = 1$), o transitorio (si $F(z; \mu_0)$ es regular en todo el intervalo considerado). En este caso, como se puede apreciar en el gráfico, como tenemos una singularidad se corresponde a recurrencia positiva.

El código que usamos para realizar el ejemplo anterior (en R) es el siguiente:

```

1 # Definir la matriz de transicion
2 P = matrix(c(0.5, 0.5, 0, 0, 0,
3             0.5, 0, 0.5, 0, 0,
4             0, 0.5, 0, 0.5, 0,
5             0, 0, 0.5, 0, 0.5,
6             0, 0, 0, 0.5, 0.5),
7           nrow = 5, byrow = TRUE)

```

```

8
9 # Funcion para calcular la funcion de Stieltjes
10 stieltjes = function(z, P, i) {
11   I = diag(nrow(P))
12   G = solve(I - z * P) # Resolviendo (I - zP)^-1
13   return(G[i + 1, i + 1]) # Devuelve la entrada (i, i)
14 }
15
16 # Valores de z
17 z_vals = seq(0, 1, by = 0.01) + 0.01i # Grilla de
    valores de z con parte imaginaria mayor a cero
18
19 # Calcular la funcion de Stieltjes para el estado 0
20 F_vals = sapply(z_vals, stieltjes, P = P, i = 0)
21
22 # Graficar la funcion de Stieltjes
23 plot(Re(z_vals), Re(F_vals), type = "l", col = "blue",
    lwd = 2,
24      xlab = "Re(z)", ylab = "Re(F(z; mu0))", main = "
    Funcion de Stieltjes para el Estado 0", ylim =
    c(0, 20))
25 lines(Re(z_vals), Im(F_vals), col = "red", lwd = 2,
    lty = 2)
26 legend("topright", legend = c("Re(F(z))", "Im(F(z))"),
    col = c("blue", "red"), lty = c(1, 2))

```

References

- [1] P. R. Halmos, *The First Systems of Weighted Differential and Integral Calculus*, Measure Theory, 1970. Disponible en: <https://archive.org/details/measuretheory00halm/page/n327/mode/2up>
- [2] R. Álvarez Nodarse, *Ortogonalidad y Aplicaciones*, Departamento de Análisis Matemático, Universidad de Sevilla, diciembre 2023. Disponible en: <https://idus.us.es/bitstream/handle/11441/152431/orthonet16.pdf?sequence=1>
- [3] R. M. Feldman y C. Valdez-Florez, *Applied Probability and Stochastic Processes*, 2nd ed., Springer, 2010. Disponible en: <https://www.fcfm.buap.mx/jzacarias/cursos/procesos/libros/book2pe.pdf>
- [4] Christian Berg, *Markov's Theorem Revisited*, Matematisk Institut, Universitetsparken 5, DK-2100 Copenhagen Ø, Denmark. Disponible en: <https://web.math.ku.dk/~berg/manus/markov.pdf>

- [5] R. G. Bartle, *The Elements of Integration and Lebesgue Measure*, Wiley Interscience, 1995.
- [6] S.-T. Li, *A Brief Introduction to Lebesgue–Stieltjes Integral*, 2024. Disponible en: <https://www.math.utah.edu/~li/L-S%20integral.pdf>
- [7] André Markov, *Deux démonstrations de la convergence de certaines fractions continues*, 1895.
- [8] The Problem of MOMENTS J.A. Shohat J. D.Tamarkin New York: American mathematical society <https://www.ams.org/books/surv/001/surv001-endmatter.pdf>
- [9] Types of probability distributions: Continuous probability distribution, Degenerate distribution, Probability mass function
- [10] E. Artin (1957) *Álgebra geométrica*, capítulos III, IV y V